



Akademia Górnictwo-Hutnicza im. Stanisława Staszica w Krakowie

Wydział Informatyki

Projekt dyplomowy

*Implementacja narzędzi lex i yacc z wykorzystaniem
metaprogramowania*

*Implementation of lexical analyzer (lex) and parser generator
(yacc) tools using metaprogramming techniques*

Autorzy: Bartosz Buczek, Bartłomiej Kozak
Kierunek studiów: Informatyka
Opiekun pracy: dr inż. Tomasz Służalec

Kraków, 2025

Spis treści

| | |
|-------------------------------------------------------------------------------------------------|-----------|
| 1 Cel pracy i wizja projektu | 5 |
| 1.1 Charakterystyka problemu | 5 |
| 1.1.1 Podstawy teoretyczne | 5 |
| 1.2 Teza i pytania badawcze | 5 |
| 1.3 Motywacja projektu | 6 |
| 1.4 Przegląd istniejących rozwiązań | 7 |
| 1.4.1 Generatory kodu | 7 |
| 1.4.2 Biblioteki interpretowane | 8 |
| 1.4.3 Kombinatory parserów | 10 |
| 1.4.4 Analiza porównawcza | 12 |
| 1.5 Ograniczenia i zakres pracy | 12 |
| 2 Metaprogramowanie w Scali 3 | 14 |
| 2.1 Wprowadzenie | 14 |
| 2.1.1 Cytaty i wstawki | 14 |
| 2.1.2 Bezpieczeństwo międzyetapowe | 14 |
| 2.2 Mechanizmy metaprogramowania w Scali 3 | 15 |
| 2.2.1 Definicje inline | 15 |
| 2.2.2 Makra oparte na wyrażeniach | 15 |
| 2.2.3 Dopasowanie wzorców w cytatach kodu | 15 |
| 2.2.4 Refleksja TASTy | 15 |
| 3 Implementacja | 17 |
| 3.1 Praktyczna implementacja analizatora leksykalnego z wykorzystaniem makr w Scali 3 | 17 |
| 3.1.1 Wprowadzenie do studium przypadku | 17 |
| 3.1.2 Interfejs użytkownika | 17 |
| 3.1.3 Implementacja makra | 18 |
| 3.1.4 Analiza i transformacja drzewa składni | 18 |
| 3.1.5 Ekstrakcja i komplikacja wzorców | 19 |
| 3.1.6 Analiza wzorców: klasa CompileNameAndPattern | 19 |
| 3.1.7 Generacja klasy anonimowej | 19 |
| 3.1.8 Typy rafinowane (refinement types) | 20 |
| 3.1.9 Uzasadnienie wybranego podejścia implementacyjnego | 22 |
| 3.1.10 Analiza alternatywnych rozwiązań | 23 |
| 3.1.11 Walidacja i obsługa błędów | 24 |
| 3.2 Praktyczna implementacja generatora parserów z wykorzystaniem makr w Scali 3 | 24 |

| | | |
|------------------------|---------------------------------------------------------------|-----------|
| 3.2.1 | Wprowadzenie do generatora parserów | 24 |
| 3.2.2 | Interfejs API parsera | 25 |
| 3.2.3 | Generacja tabel parsowania w czasie kompilacji | 26 |
| 3.2.4 | Trudne problemy rozwiązane w implementacji | 26 |
| 3.2.5 | Generacja kodu tabel | 29 |
| 3.3 | Narzędzia pomocnicze | 30 |
| 3.3.1 | Empty[T] — konstrukcja wartości domyślnych | 30 |
| 3.3.2 | ReplaceRefs — transformacja symboli w AST | 31 |
| 3.3.3 | CreateLambda — programatyczna konstrukcja wyrażeń funkcyjnych | 33 |
| 3.3.4 | Copyable[T] — generyczna funkcja kopирования | 34 |
| 3.3.5 | Porównanie z istniejącymi bibliotekami | 35 |
| Spis rysunków | | 39 |
| Spis tabel | | 40 |
| Spis algorytmów | | 41 |
| Spis listingów | | 42 |

Rozdział 1

Cel pracy i wizja projektu

1.1. Charakterystyka problemu

Analizatory leksykalne (ang. *lexers*) i składniowe (ang. *parsers*) stanowią fundamentalne komponenty procesu komplikacji, realizując odpowiednio fazę analizy leksykalnej i syntaktycznej [1]. Analizator leksykalny segmentuje ciąg znaków wejściowych na strumień tokenów (leksemów) zgodnie z regułami języka regularnego [2], podczas gdy analizator składniowy weryfikuje zgodność strumienia tokenów z gramatyką bezkontekstową języka, konstruując drzewo składni abstrakcyjnej (AST, ang. *Abstract Syntax Tree*) [1].

1.1.1. Podstawy teoretyczne

Analiza leksykalna i składniowa opiera się na teorii języków formalnych, zapoczątkowanej przez prace Noama Chomsky'ego [3]. W hierarchii Chomsky'ego języki dzieli się na cztery klasy według mocy wyrazu gramatyk je generujących. Analizatory leksykalne operują na językach regularnych (typ 3), które są rozpoznawane przez automaty skończone [2], podczas gdy parsery składniowe obsługują języki bezkontekstowe (typ 2), rozpoznawane przez automaty ze stosem [1].

Wyrażenia regularne są notacją deklaratywną dla języków regularnych i można je mechanicznie przekształcić w automaty skończone za pomocą konstrukcji Thompsona [4]. Automaty deterministyczne (DFA) gwarantują liniową złożoność czasową rozpoznawania $O(n)$, podczas gdy niedeterministyczne (NFA) mogą wymagać przeszukiwania z nawrotami (ang. *backtracking*).

Gramatyki bezkontekstowe (CFG) definiują strukturę syntaktyczną języków programowania. Parsery dla CFG dzielą się na dwie główne kategorie: parsery zstępujące rekurencyjnie (ang. *top-down*), takie jak LL(k) [5], oraz parsery wstępujące rekurencyjnie (ang. *bottom-up*), takie jak LR(k) [6]. Wybór klasy parsera determinuje kompromisy między mocą wyrazu gramatyki, złożonością implementacji oraz jakością komunikatów błędów.

1.2. Teza i pytania badawcze

W niniejszej pracy przyjęto tezę, zgodnie z którą wykorzystanie metaprogramowania w języku Scala 3 (makra kompilacyjne, typy rafinowane) umożliwia konstrukcję systemu

generującego analizatory leksykalne i składniowe charakteryzujących się następującymi właściwościami:

1. wydajność — czas parsowania porównywalny z narzędziami opartymi na generacji kodu (ANTLR, Yacc), przewyższający biblioteki interpretowane (PLY, SLY).
2. użyteczność — interfejs programistyczny (API) niezależny od dedykowanego DSL, zintegrowany z systemem typów Scali i wspierany przez standardowe narzędzia IDE.
3. diagnostyka błędów — komunikaty błędów generowane w czasie komplikacji (dla błędów gramatyki) oraz w czasie parsowania (dla błędów składniowych), zawierające kontekst syntaktyczny.

W ramach weryfikacji tezy sformułowano następujące pytania badawcze:

1. Czy możliwe jest osiągnięcie wydajności zbliżonej do generatorów kodu przy zachowaniu elastyczności bibliotek kombinatorów poprzez zastosowanie metaprogramowania?
2. W jakim stopniu wykorzystanie typów rafinowanych w Scali 3 wpływa na bezpieczeństwo typów i komfort pracy z wygenerowanym parserem?
3. Jakie ograniczenia maszyny wirtualnej Java (JVM) wpływają na proces generacji kodu w czasie komplikacji i jak można je efektywnie niwelować?

Celem pracy jest zaprojektowanie i zaimplementowanie narzędzia *ALPACA* (*Another Lexer Parser And Compiler Alpaca*) w języku Scala, które implementuje funkcjonalności powszechnie stosowane w budowie analizatorów leksykalnych i składniowych, weryfikując postawioną tezę.

1.3. Motywacja projektu

Istniejące narzędzia do konstrukcji analizatorów leksykalnych i składniowych wykazują szereg ograniczeń utrudniających ich zastosowanie w kontekście nowoczesnych języków programowania oraz środowisk deweloperskich. Identyfikacja tych ograniczeń stanowiła punkt wyjścia dla projektu *ALPACA*.

Projekt *ALPACA* stanowi narzędzie do generowania lekserów i parserów w języku Scala, łączące zalety istniejących rozwiązań poprzez:

1. Połączenie wydajności generatorów kodu z użytecznością bibliotek, czyli wykorzystanie makr kompilacyjnych Scali 3, co pozwala przenieść część obliczeń na etap komplikacji, zachowując interfejs programistyczny zintegrowany z systemem typów języka.
2. Generowanie komunikatów błędów w oparciu o kontekst parsera LR(1).
3. Natywną integrację ze środowiskami IDE, gdyż implementacja w czystym języku Scala eliminuje konieczność stosowania dedykowanych pluginów, wykorzystując istniejące wsparcie dla języka (IntelliJ IDEA, Metals).

Proponowane rozwiązanie łączy nowoczesne podejście technologiczne z praktycznym zastosowaniem w edukacji i programowaniu. Może ono służyć jako narzędzie dydaktyczne, ułatwiając naukę teorii komplikacji, w pracach badawczych, a także jako kompleksowe narzędzie do tworzenia praktycznych rozwiązań.

1.4. Przegląd istniejących rozwiązań

Narzędzia do konstrukcji analizatorów leksykalnych i składniowych można sklasyfikować według strategii implementacyjnej na trzy główne kategorie: generatory kodu, biblioteki interpretowane oraz kombinatory parserów.

1.4.1. Generatory kodu

Generatory kodu transformują deklaratywne specyfikacje gramatyk w kod źródłowy parsera w języku docelowym. Proces ten odbywa się przed komplikacją programu głównego i wymaga dodatkowego narzędzia w procesie budowania (ang. *build chain*).

Lex i Yacc

Lex [7] i *Yacc* [8] to klasyczne, dobrze ugruntowane narzędzia, które odegrały kluczową rolę w tworzeniu setek współczesnych języków programowania. Definicja leksera i parsera w tych systemach odbywa się poprzez specjalnie zaprojektowaną składnię konfiguracyjną. Narzędzia te wymuszają znajomość dedykowanej składni specyfikacji gramatyk, co utrudnia rozpoczęcie pracy dla początkujących użytkowników.

Ponieważ *Lex* i *Yacc* zostały zaprojektowane do współpracy z językiem C, ich integracja z nowoczesnymi językami programowania bywa utrudniona. Rozszerzanie tych narzędzi o dodatkowe, specyficzne funkcjonalności jest skomplikowane, co ogranicza ich elastyczność. Brak wsparcia dla współczesnych środowisk programistycznych (IDE) dodatkowo obniża komfort użytkowania w porównaniu z nowoczesnymi alternatywami.

```

1  {
2  /*%%*/
3  value_expr($3);
4  $1->nd_value = $3;
5  $$ = $1;
6  /*%
7  $$ = dispatch2(massign, $1, $3);
8  %*/
9 }
10 | var_lhs tOP_ASSIGN command_call
11 {
12 value_expr($3);
13 $$ = new_op_assign($1, $2, $3);
14 }
15 | primary_value '[' opt_call_args rbracket tOP_ASSIGN command_call
16 {
17 /*%%*/
18 NODE *args;
19
20 value_expr($6);
21 if (!$3) $3 = NEW_ZARRAY();
22 args = arg_concat($3, $6);
23 if ($5 == tOROP) {
24     $5 = 0;
25 }
26 else if ($5 == tANDOP) {
27     $5 = 1;
28 }
```

```

29 $$ = NEW_OP_ASgn1($1, $5, args);
30 fixpos($$, $1);
31 /*%
32 $$ = dispatch2(aref_field , $1, escape_Qundef($3));
33 $$ = dispatch3(opassign , $$, $5, $6);
34 %*/
35 }

```

Listing 1.1: Fragment definicji parsera Ruby w technologii Yacc

ANTLR

ANTLR [9] to rozwiązanie inspirowane narzędziami *Lex* i *Yacc*, oferujące zaawansowane mechanizmy analizy składniowej. Jego twórcy opracowali dedykowany język DSL, znany jako Grammar v4, który umożliwia definiowanie składni analizowanego języka. Na podstawie tej definicji *ANTLR* generuje parser w wybranym przez użytkownika języku programowania, takim jak Python, Java, C++ lub JavaScript.

Wspomaganie pracy z *ANTLR* w znacznym stopniu ułatwiają dedykowane wtyczki do środowisk Visual Studio Code oraz IntelliJ IDEA. Oferują one funkcjonalności, takie jak kolorowanie składni, autouzupełnianie kodu, nawigację do definicji leksemów oraz walidację błędów, co znaczco przyspiesza proces tworzenia parserów.

Jedną z kluczowych różnic *ANTLR* w porównaniu do innych narzędzi jest wykorzystanie gramatyki LL(*), podczas gdy klasyczne rozwiązania, takie jak *Yacc* czy *SLY*, implementują LALR(1). LL(*) jest bardziej intuicyjna i czytelna dla programistów, co ułatwia definiowanie reguł składniowych. Jednakże jej zastosowanie wiąże się z większym zużyciem pamięci oraz niższą wydajnością w porównaniu do LALR(1).

Dodatkowym wyzwaniem podczas korzystania z *ANTLR* jest konieczność nauki składni DSL Grammar v4 oraz ograniczenie wsparcia dla narzędzi deweloperskich. Pełne wykorzystanie możliwości *ANTLR* wymaga korzystania z jednego z dedykowanych środowisk, co może stanowić istotne ograniczenie dla użytkowników preferujących inne IDE.

1.4.2. Biblioteki interpretowane

Biblioteki interpretowane definiują gramatyki jako struktury danych w języku bazowym. Parser jest wykonywany w czasie działania programu, co eliminuje krok generacji kodu, ale wprowadza narzut wydajnościowy.

PLY i SLY

PLY [10] i jego nowszy odpowiednik *SLY* [11] to biblioteki inspirowane narzędziami *Lex* i *Yacc*. Oferują elastyczne podejście do budowy parserów, umożliwiając samodzielną implementację obsługi leksemów, budowę drzewa AST, czy dodatkowe funkcjonalności takie jak obliczanie numeru linii w leksyce.

Głównym ograniczeniem PLY i SLY jest implementacja w języku Python. Ze względu na interpretowany charakter oraz dynamiczne typowanie, parsery te charakteryzują się niską wydajnością, a brak statycznego typowania utrudnia wykrywanie błędów na etapie tworzenia analizatora leksykalnego lub składniowego. Mechanizm refleksji wykorzystywany przez bibliotekę *SLY* (inspekcja nazw metod i typów) powoduje generowanie ostrzeżeń przez analizatory statyczne środowiska PyCharm. Ponadto należy zaznaczyć, iż autor projektu informuje o braku dalszego rozwoju tych narzędzi [12].

Przykład 1.2 ilustruje kilka nieintuicyjnych, automatycznych mechanizmów obecnych w bibliotece *SLY*:

Dekorator `@()` Dekorator ten definiuje wzorzec dopasowania dla produkcji. Argumenty w cudzysłowie są traktowane jako literały, podczas gdy identyfikatory bez cudzysłowu odnoszą się do innych nieterminali.

Konwencja nazewnictwa metod Nazwa metody określa typ zwracany przez produkcję. Parser automatycznie identyfikuje wszystkie metody o danej nazwie jako alternatywne produkcje dla tego nieterminala. Mechanizm ten eliminuje potrzebę jawnej deklaracji reguł, ale utrudnia śledzenie struktury gramatyki.

Priorytet operatorów W krotce `precedence` definiowane jest pierwszeństwo operatorów, jednakże dodanie `% prec` pozwala nadpisać priorytet dla konkretnej reguły składniowej.

Dostęp do kontekstu Argument `p` pozwala na dostęp do kontekstu produkcji (np. numeru linii), ale także do zmiennych we wzorcu dopasowania w adnotacji. Jeśli zdefiniowany jest więcej niż jeden element, dodawany jest numer do akcesora, np. `expr1` jest odwołaniem do drugiego wyrażenia `expr`.

```

1 class MatrixParser(Parser):
2   tokens = MatrixScanner.tokens
3
4   precedence = (
5     ('nonassoc', 'IFX'),
6     ('nonassoc', 'ELSE'),
7     ('nonassoc', 'EQUAL'),
8   )
9
10 @_('{ " instructions " }')
11 def block(self, p: YaccProduction):
12   raise NotImplementedError
13
14 @_('instruction')
15 def block(self, p: YaccProduction):
16   raise NotImplementedError
17
18 @_('IF "(" condition ")" block %prec IFX')
19 def instruction(self, p: YaccProduction):
20   raise NotImplementedError
21
22 @_('IF "(" condition ")" block ELSE block')
23 def instruction(self, p: YaccProduction):
24   raise NotImplementedError
25
26 @_('expr EQUAL expr')
27 def condition(self, p: YaccProduction):
28   args = [p.expr0, p.expr1]
29   raise NotImplementedError

```

Listing 1.2: Fragment definicji parsera w Pythonie, wykorzystujący bibliotekę SLY

Komunikaty błędów w bibliotece *SLY* nie zawierają informacji o kontekście syntaktycznym ani sugestii poprawek, co obrazuje przykład 1.3, który po uruchomieniu informuje użytkownika błędem z fragmentu kodu 1.4. Okazuje się, że problemem był brak atrybutu `ignore_comment` w definicji `Lexer`.

```
1 tokens = Scanner().tokenize("a = 1 + 2")
2 for tok in tokens:
3     print(tok)
```

Listing 1.3: Fragment niedziałającego kodu w Pythonie, wykorzystujący bibliotekę *SLY*

```
1 File "main.py", line 2, in <module>
2     for tok in tokens:
3         ^^^^^^
4     File "Python\site-packages\sly\lex.py", line 374, in tokenize
5         _set_state(type(self))
6         ~~~~~^~~~~~^~~~~~^~~~~~^
7     File "Python\site-packages\sly\lex.py", line 367, in _set_state
8         _master_re = cls._master_re
9         ^~~~~~^~~~~~^~~~~~^
10 AttributeError: type object 'Scanner' has no attribute '_master_re'
```

Listing 1.4: Przykładowy komunikat błędu w bibliotece *SLY*

1.4.3. Kombinatory parserów

Kombinatory parserów to funkcje wyższego rzędu konstrujące złożone parsery z prostszych komponentów. Podejście to łączy elastyczność bibliotek z czytelną składnią zbliżoną do notacji BNF.

Scala parser combinators

Biblioteka *Scala parser combinators* [13] była popularnym sposobem na tworzenie parserów, lecz jak stwierdzono w samej dokumentacji: „Trudno jest jednak zrozumieć ich działanie i jak zacząć. Po skompilowaniu i uruchomieniu kilku pierwszych przykładów, mechanizm działania staje się bardziej zrozumiały, ale do tego czasu może stanowić istotną przeszkodę, a standardowa dokumentacja nie jest zbyt pomocna” [14].

ScalaBison

Z podsumowania artykułu na temat *ScalaBison* [15] wiadomo, że to praktyczny generator parserów dla języka Scala oparty na technologii rekurencyjnego wstępowania i zstępowania, który akceptuje pliki wejściowe w formacie *bison*. Parsery generowane przez *ScalaBison* używają bardziej informacyjnych komunikatów o błędach niż te generowane przez pierwotny *bison*, a także szybkość parsowania i wykorzystanie miejsca są znacznie lepsze niż *scala-combinators*, ale są nieco wolniejsze niż najszybsze generatory parserów oparte na JVM.

Dodatkowo należy zaznaczyć, iż jest to rozwiązanie już niewspierane i stworzone w celach akademickich. Korzysta z przestarzałej wersji Scali, nie posiada wyczerpującej dokumentacji i liczba funkcjonalności jest bardzo ograniczona w porównaniu do np. technologii *SLY*.

parboiled2

parboiled2 [16] to biblioteka w Scali umożliwiająca lekkie i szybkie parsowanie dolnego tekstu wejściowego. Implementuje ona oparty na makrach generator parsera dla gramatyk wyrażeń parsujących (PEG), który działa w czasie komplikacji i tłumaczy definicję reguły gramatycznej na odpowiadający jej bytecode JVM. Ze względu na skomplikowany i nieintuicyjny DSL, bariera wejścia dla nowych użytkowników jest wysoka. Zgodnie z przykładem 1.5, raportowanie błędów jest bardzo ograniczone (problem z implementacją wynika jedynie z różnic w liczbie parametrów funkcji).

```

1 [error] /Users/haoyi/Dropbox (Personal)/Workspace/scala-js-book/scalatexApi
   /src/main/scala/scalatex/stages/Parser.scala:60: overloaded
2 method value apply with alternatives:
3 [error] [I, J, K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z, RR](f: (I, J
   , K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z, scalatex.stages.Ast.
   Block,
4 Text, scalatex.stages.Ast.Chain, Int, scalatex.stages.Ast.Block) => RR)(
   implicit j: org.parboiled2.support.ActionOps.SJoin[shapeless.:::[I,
5 shapeless.:::[J,shapeless.:::[K,shapeless.:::[L,shapeless.:::[M,shapeless.:::[N,
   shapeless.:::[0,shapeless.:::[P,shapeless.:::[Q,shapeless.:::[R,
6 shapeless.:::[S,shapeless.:::[T,shapeless.:::[U,shapeless.:::[V,shapeless.:::[W,
   shapeless.:::[X,shapeless.:::[Y,shapeless.:::[Z,shapeless.
7 HNil]]]]]]]]]]]]],shapeless.HNil,RR], implicit c: org.parboiled2.
   support.FCapture[(I, J, K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z,
   scalatex.
8 stages.Ast.Block.Text, scalatex.stages.Ast.Chain, Int, scalatex.stages.Ast.
   Block) => RR])org.parboiled2.Rule[j.In,j.Out] <and>
9 [error] [J, K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z, RR](f: (J, K, L
   , M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z, scalatex.stages.Ast.Block.
   Text,
10 scalatex.stages.Ast.Chain, Int, scalatex.stages.Ast.Block) => RR)(implicit
   j: org.parboiled2.support.ActionOps.SJoin[shapeless.:::[J,
11 shapeless.:::[K,shapeless.:::[L,shapeless.:::[M,shapeless.:::[N,shapeless.:::[0,
   shapeless.:::[P,shapeless.:::[Q,shapeless.:::[R,shapeless.:::[S,
12 shapeless.:::[T,shapeless.:::[U,shapeless.:::[V,shapeless.:::[W,shapeless.:::[X,
   shapeless.:::[Y,shapeless.:::[Z,shapeless.HNil]]]]]]]]]]],shapeless.
   HNil,RR], implicit c: org.parboiled2.support.FCapture[(J, K, L, M, N, O,
   P, Q, R, S,
13 T, U, V, W, X, Y, Z, scalatex.stages.Ast.Block.Text, scalatex.stages.Ast.
   Chain, Int, scalatex.stages.Ast.Block) => RR])org.parboiled2.Rule[j.
14 In,j.Out] <and>
```

Listing 1.5: Niewielki fragment (14 z 133 linii) błędu wygenerowanego przez bibliotekę *parboiled2*, który pochodzi z prezentacji Li Haoyi na temat *FastParse* [17].

FastParse

FastParse [18] to opracowana przez Li Haoyi wysokowydajna biblioteka kombinatorów parserów dla Scali, zaprojektowana w celu uproszczenia tworzenia parserów tekstu strukturalnego. Umożliwia ona programistom definiowanie parserów rekurencyjnych, dzięki czemu nadaje się do parsowania języków programowania, formatów danych, takich jak JSON, czy DSL-i. Cechą charakterystyczną FastParse jest równowaga między użytecznością a wydajnością. Parsery są konstruowane poprzez łączenie mniejszych parserów za pomocą operatorów, takich jak \sim dla sekwencjonowania i $|$ dla alternatyw, przy

jednoczesnym zachowaniu czytelności zbliżonej do formalnych definicji gramatyki. Według dokumentacji [18], parsery *Fastparse* zajmują 1/10 kodu w porównaniu do ręcznie napisanego parsera rekurencyjnego. W porównaniu do narzędzi generujących parsery, takich jak *ANTLR* lub *Lex* i *Yacc*, implementacja nie wymaga żadnego specjalnego kroku komplikacji lub generowania kodu. To sprawia, że rozpoczęcie pracy z *Fastparse* jest znacznie łatwiejsze niż w przypadku bardziej tradycyjnych narzędzi do generowania parserów. Przykładowo, parser wyrażeń arytmetycznych może być zwięźle napisany, aby obsługiwać zagnieżdżone nawiasy, pierwszeństwo operatorów i raportowanie błędów w mniej niż 20 liniach kodu [19]. Biblioteka kładzie również nacisk na debugowanie, generując szczegółowe komunikaty o błędach, które wskazują dokładną lokalizację i przyczynę niepowodzeń parsowania, takich jak niedopasowane nawiasy lub nieprawidłowe tokeny.

1.4.4. Analiza porównawcza

Tabela 1.1 zestawia główne cechy analizowanych narzędzi. Widoczny jest kompromis między wydajnością a użytecznością: generatory kodu (*Lex/Yacc*, *ANTLR*) osiągają wysoką wydajność, ale wymagają dodatkowego kroku komplikacji i nauki DSL. Biblioteki kombinatorów (*FastParse*, *parboiled2*) oferują interfejs zintegrowany z językiem bazowym, ale kosztem spadku wydajności związanego z interpretacją reguł w czasie wykonania.

Żadne z analizowanych rozwiązań nie łączy jednocześnie:

- wysokiej wydajności (generacja kodu w czasie komplikacji),
- interfejsu API zintegrowanego z systemem typów języka,
- komunikatów błędów zawierających kontekst syntaktyczny,
- natywnej integracji ze środowiskami IDE bez dedykowanych pluginów.

Luka ta stanowi motywację dla projektu *ALPACA*, który wykorzystuje makra kompileacyjne Scali 3 do osiągnięcia tych celów jednocześnie.

1.5. Ograniczenia i zakres pracy

Niniejsza praca koncentruje się na implementacji parsera LR(1) oraz analizatora leksykalnego wykorzystującego wyrażenia regularne. Następujące aspekty wykraczają poza zakres pracy:

- System generuje kanoniczne stany LR(1) bez minimalizacji do LALR(1), co może prowadzić do większych tablic akcji. Implementacja minimalizacji stanowi potencjalny kierunek przyszłych badań.
- Ewaluacja empiryczna w kontekście dydaktycznym, czyli weryfikacja użyteczności systemu w środowisku akademickim (badanie z udziałem studentów) wykracza poza zakres pracy i stanowi kierunek przyszłych badań.

| Narzędzie | Lex&Yacc | PLY/SLY | ANTLR | scala-bison |
|-------------------------|---------------------------------|----------------------|--------------------|---------------------|
| Język implementacji | C | Python | Java | Scala (nad Bisonem) |
| Język użycia | regex, BNF, akcje w C | DSL | DSL oparty na EBNF | BNF, akcje w Scali |
| Wydajność | wysoka | niska | umiarkowana | wysoka |
| Łatwość użycia | średnia | umiarkowana | wysoka | średnia |
| Aktywne wsparcie | brak | nie | tak | nie |
| Diagnostyka błędów | słaba | średnia | dobra | słaba |
| Dokumentacja | dobra | średnia, nieaktualna | dobra | słaba |
| Popularność | wysoka | średnia | wysoka | niska |
| Integracja IDE | nieoficjalny plugin | ograniczona | oficjalny plugin | brak |
| Wsparcie do debugowania | brak | dobre | częściowe | dobre |
| Generowanie kodu | nie | nie | tak | nie |
| Narzędzie | Scala parser combinators | parboiled2 | FastParse | ALPACA |
| Język implementacji | Scala | Scala | Scala | Scala |
| Język użycia | DSL w Scali | DSL w Scali | DSL w Scali | Scala |
| Wydajność | wysoka | umiarkowana | wysoka | wysoka |
| Łatwość użycia | niska | średnia | średnia | wysoka |
| Aktywne wsparcie | nie | nie | tak | tak |
| Diagnostyka błędów | dobra | niska | dobra | dobra |
| Dokumentacja | słaba | bardzo dobra | bardzo dobra | dobra |
| Popularność | średnia | niska | rosnąca | niska |
| Integracja IDE | wsparcie dla Scali | wsparcie dla Scali | wsparcie dla Scali | wsparcie dla Scali |
| Wsparcie do debugowania | dobre | dobre | dobre | dobre |
| Generowanie kodu | nie | nie | nie | tak |

Tabela 1.1: Porównanie wybranych narzędzi do generowania analizatorów leksykalnych i składniowych

Rozdział 2

Metaprogramowanie w Scali 3

2.1. Wprowadzenie

Scala 3, znana również jako Dotty, wprowadza całkowicie przeprojektowany system metaprogramowania, stanowiący fundamentalną zmianę w stosunku do eksperymentalnych makr dostępnych w Scali 2 [20, 21]. Metaprogramowanie w Scali 3 zostało zaprojektowane z naciskiem na bezpieczeństwo typów, przenośność oraz skalowalność, umożliwiając twórcom oprogramowania generowanie i analizowanie kodu w czasie komplikacji przy zachowaniu pełnej ekspresywności języka [22, 23]. W przeciwieństwie do poprzedniego systemu, który eksponował wewnętrzne mechanizmy kompilatora i był źródłem problemów z kompatybilnością między wersjami [24], nowy system metaprogramowania jest zaprojektowany jako stabilny i przenośny interfejs programistyczny. Podstawą teoretyczną systemu metaprogramowania w Scali 3 jest programowanie wieloetapowe (ang. *multi-stage programming*), paradygmat pozwalający na odróżnienie różnych etapów wykonania programu [25, 24]. W tym modelu kod może być wykonywany w różnych fazach: w czasie komplikacji (ang. *compile-time*) lub w czasie wykonania (ang. *runtime*) [25].

2.1.1. Cytaty i wstawki

Kluczowymi koncepcjami w systemie metaprogramowania Scali 3 są cytaty (ang. *quotes*) i wstawki (ang. *splices*) [26, 27]. Cytaty (ang. *quotes*), oznaczane jako '`{ ... }`', służą do opóźnienia wykonania kodu i traktowania go jako danych [28]. Wstawki (ang. *splices*), oznaczane jako '\$`{ ... }`', pozwalają na ocenę wyrażenia generującego kod i wstawienie wyniku do otaczającego kontekstu [28, 29].

Formalna semantyka tych konstrukcji została przedstawiona w pracy Stuckiego, Brachthäusera i Odersky'ego [27], gdzie cytaty (ang. *quotes*) i wstawki (ang. *splices*) są traktowane jako prymitywne formy w typowanych drzewach składniowych (ang. *typed abstract syntax trees*). Autorzy dowodzą, że system zachowuje bezpieczeństwo typów oraz higienicznosć, zapewniając, że wygenerowany kod nie może przypadkowo powiązać identyfikatorów z niewłaściwymi zmiennymi [27].

2.1.2. Bezpieczeństwo międzyetapowe

Scala 3 gwarantuje bezpieczeństwo międzyetapowe (ang. *cross-stage safety*) poprzez sprawdzanie poziomów etapowania w czasie komplikacji [24, 27]. Zmienne lokalne mogą być

używane tylko na tym samym poziomie etapowania, na którym zostały zdefiniowane, co zapobiega dostępowi do zmiennych, które jeszcze nie istnieją lub już nie są dostępne [24].

System również zapewnia, że typy generyczne używane w wyższym poziomie etapowania niż ich definicja wymagają instancji klasy typu **Type[T]**, która niesie reprezentację typu niepoddaną wymazywaniu (ang. *type erasure*) [24]. To podejście rozwiązuje problem wymazywania typów generycznych w JVM, zachowując informację o typach potrzebną w kolejnych etapach komplikacji.

2.2. Mechanizmy metaprogramowania w Scali 3

Przedstawione powyżej podstawy teoretyczne znajdują bezpośrednie zastosowanie w praktycznych mechanizmach metaprogramowania oferowanych przez język Scala 3, które zostaną omówione w niniejszej sekcji.

2.2.1. Definicje inline

Najprostszym narzędziem metaprogramowania jest modyfikator **inline** [30]. Gwarantuje on, że wywołanie oznaczonej nim metody lub wartości zostanie w całości wstawione w miejscu wywołania (ang. *Inlining*) podczas komplikacji. Jest to instrukcja dla kompilatora, a nie tylko sugestia, jak w niektórych innych językach [31].

2.2.2. Makra oparte na wyrażeniach

Makra w Scali 3 są zdefiniowane jako metody **inline** zawierające wstawkę najwyższego poziomu (ang. *top-level splice*) [32, 33], czyli taki, który nie jest zagnieżdżony w żadnym cytacie (ang. *quote*) i jest wykonywany w czasie komplikacji [25, 32].

Typ **Expr[T]** reprezentuje wyrażenie Scali o typie T jako typowane drzewo składniowe [28, 33]. Makra manipulują wartościami typu **Expr[T]**, transformując je lub generując nowe wyrażenia [33]. Ta reprezentacja gwarantuje bezpieczeństwo typów na poziomie języka metaprogramowania [28].

2.2.3. Dopasowanie wzorców w cytatach kodu

Scala 3 wspiera analizę kodu poprzez dopasowanie wzorców w cytatach kodu (ang. *quote pattern matching*) [24, 27]. Mechanizm ten pozwala na dekonstrukcję kawałków kodu i ekstrakcję podwyrażeń [27].

Stucki, Brachthäuser i Odersky [27] wprowadzają wzorce wiążące (ang. *bind patterns*) postaci **\$x** oraz wzorce HOAS (ang. *Higher-Order Abstract Syntax*) postaci **\$f(y)**, które pozwalają na ekstrakcję podwyrażeń potencjalnie zawierających zmienne z zewnętrznego kontekstu. System gwarantuje, że ekstrahowane wyrażenia są zamknięte względem definicji wewnętrz wzorca, zapobiegając wyciekom zakresu.

2.2.4. Refleksja TASTy

Dla przypadków wymagających głębszej analizy kodu, Scala 3 oferuje API refleksji TASTy [28, 34]. TASTy jest binarnym formatem serializacji typowanych drzew składniowych używanym przez kompilator Scali 3 [24].

API refleksji dostarcza szczegółowy widok na strukturę kodu, włączając typy, symbole oraz pozycje w kodzie źródłowym. Jest dostępne poprzez obiekt `reflect` zdefiniowany w typie `Quotes`, który jest przekazywany kontekstualnie do makr [28, 34].

Rozdział 3

Implementacja

3.1. Praktyczna implementacja analizatora leksykalnego z wykorzystaniem makr w Scali 3

3.1.1. Wprowadzenie do studium przypadku

Rozdział przedstawia implementację systemu analizy leksykalnej wykorzystującego mechanizmy metaprogramowania Scali 3 [32]. Implementacja stanowi studium przypadku zastosowania technik opisanych w rozdziale poprzednim w kontekście automatycznej generacji analizatora leksykalnego. System transformuje deklaratywne reguły tokenizacji, wyrażone w języku dziedzinowym (DSL), w kod proceduralny wykonywany w czasie komplikacji, wykorzystując refleksję TASTy [28] oraz typy rafinowane [35].

System **alpaca.lexer** implementuje transformację deklaratywnych reguł tokenizacji zapisanych jako funkcja częściowa (ang. *partial function*) w kod proceduralny wykonywany w czasie komplikacji. Celem tej transformacji jest *wyeliminowanie* narzutu analizy wyrażeń regularnych i budowy automatów w czasie działania aplikacji, a także zapewnienie bezpieczeństwa typów dla wygenerowanych tokenów. Wykorzystuje przy tym pełne spektrum możliwości refleksji TASTy [28], włączając generację klas w czasie komplikacji, transformację drzew AST [34] oraz wyspecjalizowane typy refinement.

3.1.2. Interfejs użytkownika

System udostępnia interfejs języka dziedzinowego (DSL) oparty na dopasowaniu wzorców, umożliwiający deklaratywne wyrażenie reguł tokenizacji:

```
1 type LexerDefinition[Ctx <: LexerCtx] = PartialFunction[String, Token[?,  
Ctx, ?]]
```

Listing 3.1: Definicja typu LexerDefinition

Definicja **LexerDefinition** reprezentuje reguły leksera jako funkcję częściową mapującą wzorce wyrażeń regularnych (jako ciągi znaków) na definicje tokenów. Wykorzystanie funkcji częściowej pozwala na naturalne wyrażenie reguł leksykalnych w idiomatycznej składni Scali.

Metoda **lexer** definiuje główny interfejs systemu:

```
1 transparent inline def lexer[Ctx <: LexerCtx](  
2   using Ctx withDefault LexerCtx.Default,
```

```

3 |  )(  

4 |   inline rules: Ctx ?=> LexerDefinition[Ctx],  

5 |  )(using  

6 |   copy: Copyable[Ctx],  

7 |   betweenStages: BetweenStages[Ctx],  

8 |  )(using inline  

9 |   debugSettings: DebugSettings,  

10 | ): Tokenization[Ctx]

```

Listing 3.2: Punkt wejścia: transparent inline def lexer

Modyfikator **transparent inline** zapewnia, że zwracany typ będzie dokładnie odpowiadał wygenerowanej strukturze, włączając typy refinement dla poszczególnych tokenów. Użycie parametrów kontekstowych (**using**) realizuje wzorzec dependency injection na poziomie systemu typów.

3.1.3. Implementacja makra

Makro przyjmuje wyrażenie reprezentujące reguły analizatora leksykalnego jako `Expr[Ctx ?=> LexerDefinition[Ctx]]` oraz instancje kontekstualnych klas pomocniczych. Parametr **using Quotes** dostarcza dostępu do API refleksji TASTy [23, 29, 32].

3.1.4. Analiza i transformacja drzewa składni

Dekonstrukcja funkcji częściowej

Kluczowym krokiem implementacji jest ekstrakcja reguł z definicji funkcji częściowej:

```

1 val Lambda(oldCtx :: Nil, Lambda(_, Match(_, cases: List[CaseDef]))) =  
  rules.asTerm.underlying

```

Listing 3.3: Dekonstrukcja funkcji częściowej (dopasowanie AST do CaseDef)

Fragment ten wykorzystuje dopasowanie wzorców w cytatach (ang. *quotes*) do dekonstrukcji [29] typowanego AST funkcji częściowej. Struktura `Lambda(_, Match(_, cases))` odpowiada wewnętrznej reprezentacji funkcji częściowej, gdzie `Match` zawiera listę przypadków `CaseDef`.

Transformacja i adaptacja referencji

Klasa replacerefs

Kluczową techniką jest zastąpienie referencji do starego kontekstu nowymi referencjami:

```

1 def replaceWithNewCtx(newCtx: Term) = new ReplaceRefs[quotes.type].apply(  

2   (find = oldCtx.symbol, replace = newCtx),  

3   (find = tree.symbol, replace = Select.unique(newCtx, "LastRawMatched")),  

4 )

```

Listing 3.4: Zastąpienie referencji starego kontekstu nowymi (ReplaceRefs)

Transformacja realizuje proces przepisania właściciela (*re-owning*) symboli w AST, polegający na modyfikacji referencji kontekstowych w celu dostosowania ich do nowego zakresu leksykalnego [34]. Klasa **ReplaceRefs** udostępnia **TreeMap**, który podczas przejścia po AST podmienia referencje do wskazanych symboli na podane termy[34].

3.1.5. Ekstrakcja i komplikacja wzorców

Funkcja extractSimple

Funkcja **extractSimple** implementuje logikę dopasowania różnych typów definicji tokenów:

```

1 def extractSimple(
2   ctxManipulation: Expr[CtxManipulation[Ctx]],
3 ): PartialFunction[Expr[ThisToken], List[Expr[ThisToken]]] =
4   case '{ Token.Ignored(using $ctx) } =>
5     // ...
6
7   case '{ type t <: ValidName; Token.apply[t](using $ctx) } =>
8     // ...
9
10  case '{ type t <: ValidName; Token.apply[t]($value: String)(using $ctx)
11    } if value.asTerm.symbol == tree.symbol =>
12    // ...
13
14  case '{ type t <: ValidName; Token.apply[t]($value: v)(using $ctx) } =>
15    // ...

```

Listing 3.5: Funkcja extractSimple: dopasowywanie definicji tokenów

Wykorzystuje ona dopasowanie wzorców w cytatach (ang. *quotes*) z ekstraktorem typów[29], umożliwiając rozróżnienie różnych wariantów definicji tokenów na poziomie typów. Konstrukcja **type t <: ValidName** w wzorcu wiąże parametr typu do zmiennej wzorca **t**, umożliwiając jego późniejsze wykorzystanie.

Ekstrakcja definicji tokenów wymaga następnie ich analizy i walidacji, co realizuje klasa **CompileNameAndPattern**.

3.1.6. Analiza wzorców: klasa CompileNameAndPattern

Klasa **CompileNameAndPattern** odpowiada za ekstrakcję i walidację wzorców tokenów podczas ekspansji makra[32]. Jej głównym zadaniem jest transformacja wzorców występujących w definicjach DSL. Wzorce te są przekształcane w struktury **TokenInfo**, które następnie są wykorzystywane do generacji finalnego kodu leksera.

Implementacja wykorzystuje rekurencyjne przetwarzanie drzewa AST z zastosowaniem optymalizacji rekurencji ogonowej (@tailrec), co eliminuje ryzyko przepełnienia stosu dla złożonych wzorców.

3.1.7. Generacja klasy anonimowej

Kluczowym mechanizmem implementacyjnym makra **lexer** jest programatyczna konstrukcja klasy anonimowej w czasie komplikacji[27]. Proces ten wykorzystuje API re-

fleksji TASTy^[28] do dynamicznego tworzenia struktur typów, które następnie są materalizowane jako kod bajtowy JVM.

Konstrukcja symbolu klasy

Anonimowa klasa implementująca `Tokenization[Ctx]` jest tworzona poprzez wywołanie `Symbol.newClass`:

Metoda `Symbol.newClass` przyjmuje następujące parametry:

- `Symbol.spliceOwner` — właściciel nowego symbolu w hierarchii definiowania, zapewniający poprawną widoczność w zakresie leksykalnym
- `Symbol.freshName(``\$anon``)` — generowanie unikalnej nazwy klasy zgodnie z konwencją kompilatora Scali dla klas anonimowych
- `List(TypeRepr.of[Tokenization[Ctx]])` — lista typów bazowych, w tym przypadku pojedyncza implementacja abstrakcyjnej klasy `Tokenization`
- `decls` — funkcja dostarczająca listę deklaracji członków klasy (pół i metod)

Definicja członków klasy

Funkcja `decls` konstruuje pełną listę deklaracji dla klasy anonimowej:

1. dla każdego zdefiniowanego tokena tworzony jest symbol pola typu `DefinedToken[Name, Ctx, Value]`.
2. `Type alias Fields` — typ pomocniczy w formie `NamedTuple` ułatwiający strukturalny dostęp do tokenów.
3. `Pole compiled` —li wartość typu `Regex` zawierająca skompilowane wyrażenie regularne dla wszystkich tokenów.
4. `Pole tokens` — lista wszystkich zdefiniowanych tokenów (włączając ignorowane).
5. `Pole byName` — czyli mapa umożliwiająca dynamiczny dostęp do tokenów po nazwie.

Materializacja klasy

Po zdefiniowaniu symbolu klasy następuje konstrukcja jej ciała. Klasa jest następnie instancjonowana poprzez wywołanie jej konstruktora.

3.1.8. Typy rafinowane (refinement types)

Typy rafinowane (*refinement types*) stanowią mechanizm systemu typów Scali umożliwiający dodanie informacji o strukturze typu w czasie komplikacji [35]. W kontekście implementacji leksera typy rafinowane pozwalają na dodanie informacji o polach tokenów bezpośrednio do typu zwracanego przez makro.

Proces rafinowania typu

Typ wynikowy jest konstruowany poprzez iteracyjne rafinowanie typu bazowego[34]:

```

1 definedTokens
2   .unsafeFoldLeft(TypeRepr.of[Tokenization[Ctx]]):
3     case (tpe, '{ $token: DefinedToken[name, Ctx, value] }) =>
4       Refinement(tpe, ValidName.from[name], token.asTerm.tpe)
5     .asType match
6     case '[refinedTpe] =>
7       val newCls =
8         Typed(NewTypeIdent(cls)).select(cls.primaryConstructor).appliedToNone,
9         TypeTree.of[refinedTpe])
10
11   Block(clsDef :: Nil, newCls).asExprOf[Tokenization[Ctx] & refinedTpe]

```

Listing 3.6: Rafinowanie typu wynikowego o pola tokenów

Funkcja **Refinement(tpe, name, memberType)** tworzy nowy typ będący rozszerzeniem typu. Operacja ta jest wykonywana w czasie komplikacji i nie generuje dodatkowego kodu w czasie wykonania.

Wynikowy typ

Wynikowy typ ma formę typu przecięcia (ang. *intersection type*):

```

1 Tokenization[Ctx] & {
2   val TOKEN1: DefinedToken["NAME1", Ctx, Type1]
3   val TOKEN2: DefinedToken["NAME2", Ctx, Type2]
4   ...
5 }

```

Listing 3.7: Wynikowy typ leksera

Ten typ reprezentuje wartości będące jednocześnieinstancjami **Tokenization[Ctx]** oraz posiadające określone pola strukturalne (ang. *computed field names*).

Dostęp do pól tokenów odbywa się poprzez **trait Selectable**. Standardowa implementacja tego mechanizmu, opisana w dokumentacji [35], wprowadza narzut związanego z dynamicznym wyborem nazwy pola (refleksja). W prezentowanym rozwiążaniu narzut ten jest eliminowany poprzez precyzyjne typowanie strukturalne. Aby mechanizm **Selectable** działał poprawnie ze strukturalnymi typami i nie wymagał refleksji, klasa generowana przez makro musi implementować **type Fields <: NamedTuple.AnyNamedTuple**[36]. W naszym podejściu makro generuje definicję **type Fields** zawierającą wszystkie zdefiniowane tokeny i ich typy, dzięki czemu:

- IDE i kompilator dysponują informacją o dostępnych polach i ich typach (pełne uzupełnianie i sprawdzanie typów),
- wywołanie **c.NAZWA** jest bezpieczne typowo mimo mechanizmu dynamicznego wyboru nazwy.

```

1 val fieldTpe = definedTokens
2   .unsafeFoldLeft[(Type[? <: Tuple], Type[? <:
3     Tuple])]((Type.of[EmptyTuple], Type.of[EmptyTuple])):
4     case (
5       ('[type names <: Tuple; names], '[type types <: Tuple; types]),
6       '{ $token: DefinedToken[name, Ctx, value] },
7       ) =>
8         (Type.of[name *: names], Type.of[Token[name, Ctx, value] *: types])
9       .runtimeChecked
10      .match
11        case ('[type names <: Tuple; names], '[type types <: Tuple; types]) =>
12          TypeRepr.of[NamedTuple[names, types]]

```

Listing 3.8: Tworzenie typuFields

3.1.9. Uzasadnienie wybranego podejścia implementacyjnego

Eliminacja narzutu wykonania w czasie działania programu

Wszystkie definicje tokenów są rozwiązywane statycznie w czasie komplikacji[23]. Dostęp do tokenów realizowany jest jako bezpośrednie odwołanie do pola klasy, które w kodzie bajtowym JVM [37] reprezentowane jest przez instrukcję **getfield** o złożoności czasowej O(1). Teoretycznie eliminuje to narzut związany z operacjami dynamicznymi, choć pełna weryfikacja empiryczna tego założenia wykracza poza zakres niniejszej pracy.

Alternatywne podejście oparte na strukturze mapującej (np. **Map[String, Token]**) wymagałoby:

- Obliczenia funkcji haszującej dla klucza
- Przeszukiwania tablicy haszującej
- Potencjalnej obsługi kolizji
- Dynamicznego rzutowania typu

co wprowadzałoby znaczący narzut wydajnościowy oraz eliminowało możliwość optymalizacji przez kompilator.

Bezpieczeństwo typów na poziomie systemu

Dzięki typom rafinowanym każdy token posiada precyzyjny typ znany kompilatorowi[35]. System typów weryfikuje poprawność wszystkich operacji w czasie komplikacji, eliminując możliwość błędów związanych z niepoprawnym typowaniem wartości tokenów.

Integracja z narzędziami deweloperskimi

Ponieważ tokeny są reprezentowane jako rzeczywiste pola w typie, środowiska deweloperskie (IDE) mogą wykorzystać informacje typu do:

- Automatycznego uzupełniania nazw tokenów
- Prezentacji pełnych sygnatur typów przy najechaniu kursorem

- Nawigacji do definicji przez mechanizm *go-to-definition*
- Wykrywania błędów składniowych przed komplikacją

Te funkcjonalności są niemożliwe do realizacji w przypadku dostępu przez struktury dynamiczne.

Statyczna detekcja konfliktów wzorców

Makro przeprowadza analizę wszystkich wzorców w czasie komplikacji, wykrywając potencjalne konflikty nakładających się wyrażeń regularnych. Mechanizm ten zapewnia, że błędy konfiguracji są wykrywane na etapie komplikacji, a nie w czasie wykonania programu, co jest zgodne z zasadą *fail-fast* w inżynierii oprogramowania.

Typowanie strukturalne z gwarancjami nominalnymi

Zastosowanie typów rafinowanych[35] łączy zalety typowania strukturalnego (elastyczność w dostępie do składowych) z bezpieczeństwem typowania nominalnego (jednoznaczna identyfikacja typów). Każde pole w typie rafinowanym ma precyzyjny typ nominalny, podczas gdy dostęp do tych pól odbywa się przez nazwę, co zapewnia elastyczność interfejsu.

3.1.10. Analiza alternatywnych rozwiązań

Podejście oparte na mapowaniu dynamicznym

Alternatywne podejście mogłoby wykorzystywać strukturę mapującą do przechowywania tokenów:

```

1 class SimpleLexer {
2   val tokens: Map[String, Token[?, ?, ?]] = Map(
3     "NUMBER" -> ...,
4     "PLUS" -> ...
5   )
6   def apply(name: String): Token[?, ?, ?] = tokens(name)
7 }
```

Listing 3.9: Podejście oparte na mapowaniu dynamicznym

Wady tego podejścia:

- Brak bezpieczeństwa typów: błędne nazwy tokenów wykrywane są dopiero w czasie wykonania
- Utrata informacji o typach: zwracany typ to egzystencjalny **Token[?, ?, ?]**
- Narzut wydajnościowy operacji haszowania i przeszukiwania
- Brak wsparcia narzędzi deweloperskich

Podejście oparte na jawnej definicji klasy

Innym rozwiązaniem byłoby jawne definiowanie klasy leksera przez użytkownika:

```

1 class MyLexer extends Tokenization[DefaultGlobalCtx] {
2   val NUMBER = DefinedToken[...]
3   val PLUS = DefinedToken[...]
4   protected def compiled: Regex = "(?<token0>[0-9]+) | (?<token1>\+)" .r
5   // ...
6 }
```

Listing 3.10: Podejście oparte na jawnej definicji klasy

Wady tego podejścia:

- Wysoki poziom redundancji kodu (*boilerplate*)
- Konieczność ręcznej komplikacji wyrażeń regularnych
- Podatność na błędy synchronizacji między definicjami tokenów a wyrażeniem regularnym
- Brak mechanizmu DSL ułatwiającego definicję reguł

3.1.11. Walidacja i obsługa błędów

Walidacja wzorców regularnych

System wykorzystuje pomocniczą klasę **RegexChecker** do walidacji wzorców: Mechanizm ten sprawdza poprawność składni wyrażeń regularnych już w czasie komplikacji i raportuje błędy z dokładną lokalizacją wzorca. Metoda **report.errorAndAbort** przerywa komplikację i wyświetla komunikat o błędzie, eliminując konieczność detekcji błędów w czasie wykonania, co jest zgodne z zasadą wcześniejszej walidacji (*fail-fast*) [32, 33].

Obsługa nieobsługiwanych konstrukcji

Kod jawnie sygnalizuje nieobsługiwane przypadki: Obsługiwane są wyłącznie jasno zdefiniowane formy wzorców; w przypadku napotkania innej konstrukcji komplikacja jest przerwana z komunikatem zawierającym szczegółowe AST, co upraszcza diagnostykę i utrzymuje zasadę fail-fast. Ta strategia jest zgodna z zasadą fail-fast - lepiej jest wyraźnie odrzucić nieobsługiwane konstrukcje niż milcząco generować niepoprawny kod.

3.2. Praktyczna implementacja generatora parserów z wykorzystaniem makr w Scali 3

3.2.1. Wprowadzenie do generatora parserów

Implementacja generatora parserów w systemie *ALPACA* wykorzystuje mechanizmy metaprogramowania Scali 3[32] do konstrukcji tabel parsowania LR(1) w czasie komplikacji. Podejście to łączy zalety generatorów kodu (wydajność wykonania, statyczna walidacja gramatyki) z elastycznością bibliotek (integracja z systemem typów, brak dodatkowego kroku komplikacji).

Realizacja napotkała szereg wyzwań technicznych, z których najistotniejsze to:

- Konstrukcja tabel LR(1) w czasie komplikacji z wykorzystaniem makr
- Integracja z systemem typów Scali w akcjach semantycznych
- Obejście ograniczenia rozmiaru metod JVM poprzez fragmentację generowanego kodu
- Deklaratywny mechanizm rozwiązywania konfliktów gramatycznych
- Walidacja gramatyk podczas komplikacji z komunikatami o błędach

W szczególności ograniczenie rozmiaru metod JVM ilustruje istotny aspekt praktycznego metaprogramowania: generowany kod musi nie tylko być poprawny funkcjonalnie, ale również respektować wszystkie techniczne ograniczenia platformy docelowej.

3.2.2. Interfejs API parsera

Definicja parsera

Użytkownik definiuje parser poprzez dziedziczenie po klasie bazowej **Parser[Ctx]**:

```

1 abstract class Parser[Ctx <: ParserCtx](
2   using Ctx withDefault ParserCtx.Empty,
3 )(using
4   empty: Empty[Ctx],
5   tables: Tables[Ctx],
6 ) {

```

Listing 3.11: Klasa bazowa Parser

Typ parametryczny **Ctx** reprezentuje globalny kontekst parsera, umożliwiający przechowywanie stanu między akcjami semantycznymi (np. tablicę symboli). Parametr kontekstualny **tables: Tables[Ctx]** jest automatycznie generowany przez makro i zawiera tabele parsowania oraz akcji semantycznych.

Definicja reguł gramatycznych

Reguły gramatyczne definiowane są jako wartości typu **Rule[R]**, gdzie **R** określa typ wyniku redukcji:

```

1 val Expr: Rule[Double] = rule(
2   { case (Expr(a), CalcLexer.PLUS(_), Term(b)) => a + b },
3   { case (Expr(a), CalcLexer_MINUS(_), Term(b)) => a - b },
4   { case Term(t) => t },
5 )

```

Listing 3.12: Przykład definicji reguł parsera

Składnia wykorzystuje dopasowanie wzorców Scali do wyrażenia produkcji gramatycznych. Każdy przypadek (**case**) reprezentuje pojedynczą produkcję, gdzie lewa strona wzorca odpowiada prawej stronie produkcji gramatycznej, a wyrażenie po strzałce (\Rightarrow) definiuje akcję semantyczną. Na przykład wzorzec **{ case (Expr(a), CalcLexer.PLUS(_), Expr(b)) => a + b }** odpowiada produkcji **Expr → Expr PLUS Expr** z akcją sumującą wartości podwyrażeń.

3.2.3. Generacja tabel parsowania w czasie komplikacji

Makro `createTablesImpl`

Centralnym elementem systemu jest makro `createTablesImpl`, które analizuje definicję parsera i generuje tabele w czasie komplikacji:

Makro wykonuje następujące kroki:

1. Ekstrakcja wszystkich reguł gramatycznych z definicji parsera poprzez refleksję TASTy
2. Transformacja wzorców dopasowania na produkcje gramatyczne
3. Konstrukcja automatów LR(1) i tabel parsowania
4. Generacja tabel akcji semantycznych
5. Walidacja gramatyki i rozwiązywanie konfliktów

Ekstrakcja produkcji z wzorców

Funkcja `extractEBNF` dokonuje transformacji wzorców dopasowania na produkcje gramatyczne:

Kluczowym wyzwaniem jest zachowanie poprawności referencji do symboli przy przekształcaniu kodu akcji semantycznej z kontekstu definicji reguły do wygenerowanej tabeli akcji. Wymaga to zastosowania techniki *re-owning* symboli, realizowanej przez klasę `ReplaceRefs`.

3.2.4. Trudne problemy rozwiążane w implementacji

Problem ograniczenia rozmiaru metod JVM

Jednym z kluczowych wyzwań technicznych napotkanych podczas implementacji było ograniczenie rozmiaru metod w maszynach wirtualnych JVM. Zgodnie ze specyfikacją JVM[37], rozmiar kodu bajtowego pojedynczej metody nie może przekroczyć 65536 bajtów (64 KB). Dla złożonych gramatyk z dużą liczbą stanów i produkcji, wygenerowane tabele parsowania mogą zawierać tysiące wpisów, co przy naiwnej implementacji prowadziło do przekroczenia tego limitu.

Problem manifestował się podczas próby wyrażenia tabeli parsowania jako literała mapowego w kodzie:

```

1 '{  
2     Map(  
3         (0, Terminal("PLUS")) -> Shift(1),  
4         (0, Terminal("NUMBER")) -> Shift(2),  
5         ...  
6         (999, Terminal("EOF")) -> Reduction(prod),  
7     )  
8 }
```

Listing 3.13: Naiwna implementacja prowadząca do przekroczenia limitu

Takie podejście generuje pojedynczą, dużą metodę zawierającą wszystkie wpisy tabeli, co dla gramatyk o rozmiarze produkcyjnym skutkuje błędem komplikacji **Method too large**[38].

Rozwiążanie: Problem został rozwiązany poprzez zastosowanie techniki *fragmentacji metod*. Zamiast generować jeden duży literal mapy, każdy wpis tabeli jest dodawany w osobnej, małej metodzie pomocniczej:

```

1   val additions = entries
2     .map(entry =>
3       '{'
4         def avoidTooLargeMethod(): Unit = $builder += ${ Expr(entry) }
5         avoidTooLargeMethod()
6       }.asTerm,
7     )
8

```

Listing 3.14: Rozwiążanie problemu rozmiaru metod przez fragmentację

W tym podejściu:

- Tworzymy builder mapy jako zmienną lokalną (**Map.newBuilder**)
- Każde dodanie wpisu do buildera jest opakowane w osobną metodę **avoidTooLargeMethod()**
- Metody te są wywoływanie sekwencyjnie jako lista wyrażeń w bloku
- Końcowy wynik jest uzyskiwany przez wywołanie **builder.result()**

Zastosowana technika fragmentacji skutecznie eliminuje problem przekroczenia limitu rozmiaru metody. Każda metoda pomocnicza zawiera jedynie kilka instrukcji bajtowych (typowo 5–10 w zależności od złożoności wpisu tabeli), co gwarantuje zgodność ze specyfikacją JVM [37]. Dodatkowo kompilator JIT może efektywnie zoptymalizować te metody poprzez **inlining**, eliminując narzut wywołań funkcji w czasie wykonania.

Rozwiążanie to ilustruje ważną lekcję w metaprogramowaniu: kod generowany przez makra musi respektować wszystkie ograniczenia platformy docelowej, które normalnie są niewidoczne dla programistów piszących kod ręcznie.

Zachowanie bezpieczeństwa typów w akcjach semantycznych

Kolejnym istotnym wyzwaniem jest zapewnienie bezpieczeństwa typów w akcjach semantycznych podczas transformacji kodu z kontekstu makra do wygenerowanych tabel. Akcje semantyczne definiowane przez użytkownika mogą odwoływać się do:

- Kontekstu parsera (**ctx**)
- Wartości z dopasowanych symboli gramatycznych
- Zewnętrznych funkcji i wartości

Problem polega na tym, że te referencje muszą zostać przepisane podczas przenoszenia kodu akcji z miejsca definicji do tabeli akcji. Funkcja **createAction** realizuje tę transformację:

```

1   def createAction(binds: List[Option[Bind]], rhs: Term) =
2     createLambda[Action[Ctx]]:
3       case (methSym, (ctx: Term) :: (param: Term) :: Nil) =>
4         val seqApplyMethod =
5           param.select(TypeRepr.of[Seq[Any]].typeSymbol.methodMember("apply").head)
6           val seq = param.asExprOf[Seq[Any]]
7
7   val replacements = (find = ctxSymbol, replace = ctx) ::=
8     binds.zipWithIndex
9     .collect:
10      case (Some(bind), idx) => ((bind.symbol,
11        bind.symbol.typeRef.asType), Expr(idx))
12        .unsafeFlatMap:
13          case ((bind, '[t]), idx) => Some((find = bind, replace =
14            '{ $seq($idx).asInstanceOf[t] }.asTerm))
15
16   replaceRefs(replacements*).transformTerm(rhs)(methSym)

```

Listing 3.15: Tworzenie akcji semantycznej z zachowaniem referencji

Kluczowe aspekty implementacji:

1. Akcja jest transformowana w funkcję przyjmującą kontekst (**ctx**) oraz listę dzieci w drzewie parsowania (**param**)
2. Referencje do kontekstu parsera są zastępowane parametrem funkcji
3. Wartości z dopasowanych symboli są ekstrahowane z listy dzieci poprzez indeksowanie
4. System typów zapewnia, że ekstrakcje są bezpieczne względem typów dzięki informacji z wzorca dopasowania

Rozwiązywanie konfliktów gramatycznych

Parser LR może napotkać konflikty typu shift-reduce lub reduce-reduce podczas konstrukcji tabel parsowania. System ALPACA oferuje deklaratywny mechanizm rozwiązywania takich konfliktów poprzez relacje precedencji:

```

1 override val resolutions = Set(P.ofName("times").before(Lexer.PLUS),
2                               P.ofName("plus").after(Lexer.TIMES))

```

Listing 3.16: Deklaracja rozwiązań konfliktów

Implementacja wykorzystuje klasę **ConflictResolutionTable**, która podczas konstrukcji tabeli parsowania:

1. Wykrywa konflikty między akcjami dla danego stanu i symbolu
2. Analizuje zdefiniowane przez użytkownika relacje precedencji
3. Wybiera odpowiednią akcję zgodnie z deklaracją
4. Zgłasza błąd komplikacji dla nieroziwiązanych konfliktów

To podejście umożliwia wyrażenie precedencji i łączności operatorów w sposób bardziej naturalny niż tradycyjne narzędzia **%left**, **%right** i **%nonassoc** w SLY[11].

3.2.5. Generacja kodu tabel

Implementacja ToExpr dla złożonych struktur

System wymaga konwersji struktur danych w czasie komplikacji (wartości) na kod (wyrażenia `Expr[T]`). Realizowane jest to poprzez implementację instancji `ToExpr` dla typów `ParseTable` i `ActionTable`.

Implementacja `ToExpr[ParseTable]` jest szczególnie interesująca, gdyż musi rańdzić sobie z potencjalnie dużymi tabelami (patrz 3.2.4):

```

1  given ToExpr[ParseTable] with
2    def apply(entries: ParseTable)(using quotes: Quotes): Expr[ParseTable]
3    = {
4      import quotes.reflect./*
5
6      type BuilderTpe = mutable.Builder[
7        ((state: Int, stepSymbol: parser.Symbol), Shift | Reduction),
8        Map[(state: Int, stepSymbol: parser.Symbol), Shift | Reduction],
9      ]
10
11     val symbol = Symbol.newVal(
12       Symbol.spliceOwner,
13       Symbol.freshName("builder"),
14       TypeRepr.of[BuilderTpe],
15       Flags.Mutable,
16       Symbol.noSymbol,
17     )
18
19     val valDef = ValDef(symbol, Some('{ Map.newBuilder: BuilderTpe
20   }.asTerm))
21
22     val builder = Ref(symbol).asExprOf[BuilderTpe]
23
24     val additions = entries
25     .map(entry =>
26       '{{
27         def avoidTooLargeMethod(): Unit = $builder += ${Expr(entry)}
28         avoidTooLargeMethod()
29       }.asTerm,
30     )
31     .toList
32
33     val result = '{ $builder.result() }.asTerm
34
35     Block(valDef :: additions, result).asExprOf[ParseTable]

```

Listing 3.17: Implementacja `ToExpr` dla `ParseTable`

Ta implementacja demonstruje zaawansowane techniki metaprogramowania:

- Tworzenie nowych symboli (`Symbol newVal`) reprezentujących zmienne w generowanym kodzie
- Konstrukcja definicji wartości (`ValDef`) z przypisaniem początkowym
- Generacja listy wyrażeń manipulujących builderem

- Składanie wszystkiego w blok kodu (**Block**) z finalnym wynikiem

3.3. Narzędzia pomocnicze

Implementacja systemu *ALPACA* wykorzystuje zaawansowane mechanizmy metaprogramowania Scali 3, w tym refleksję TASTy [28], derywację typów [39] oraz transformację drzew składni abstrakcyjnej (AST) [34]. Realizacja tych mechanizmów wymaga zestawu narzędzi pomocniczych abstrahujących typowe wzorce operacji na typach i drzewach.

Niniejsza sekcja przedstawia cztery kluczowe komponenty infrastrukturalne:

- **Empty[T]** — generyczna konstrukcja wartości domyślnych dla typów produktowych,
- **ReplaceRefs** — transformacja drzew AST poprzez podstawianie symboli,
- **CreateLambda** — programatyczna konstrukcja wyrażeń funkcyjnych w czasie komplikacji,
- **Copyable[T]** — generyczna funkcja kopiowania dla klas przypadku (*case classes*).

Narzędzia te realizują wzorce projektowe typowe dla systemów opartych na makrach komplikacyjnych [40], eliminując powtarzalny kod (*boilerplate*) oraz zapewniając bezpieczeństwo typów na poziomie komplikacji.

3.3.1. Empty[T] — konstrukcja wartości domyślnych

Klasa typu **Empty[T]** stanowi abstrakcję nad mechanizmem konstrukcji wartości domyślnych dla typów produktowych (ang. *product types*) [41]. W systemie typów Scali [42] typy produktowe odpowiadają klasom przypadku (*case classes*) oraz krotkom (*tuples*), będącym reprezentacją iloczynów kartezjańskich typów składowych.

Motywacja

Podczas ekspansji makr komplikacyjnych często zachodzi potrzeba utworzenia instancji typu **T** bez znajomości jego konkretnej struktury. Standardowe podejście wymagałoby:

- ręcznej specyfikacji wartości wszystkich pól,
- naruszenia abstrakcji poprzez dostęp do wewnętrznej struktury typu,
- utraty bezpieczeństwa typów w przypadku zmiany definicji **T**.

Klasa typu **Empty[T]** rozwiązuje ten problem poprzez automatyczną derywację funkcji konstruującej na podstawie wartości domyślnych parametrów konstruktora [39].

Definicja

```
1 private[alpaca] trait Empty[T] extends (() => T)
```

Listing 3.18: umożliwiającej konstrukcję wartości domyślnych]Definicja klasy typu **Empty[T]** umożliwiającej konstrukcję wartości domyślnych

Typ `Empty[T]` jest reprezentowany jako funkcja zerargumentowa $() \Rightarrow T$, co umożliwia leniwe tworzenie instancji (*lazy instantiation*). Atrybut `private[alpaca]` ogranicza widoczność do pakietu, zapobiegając przypadkowemu użyciu poza systemem.

Mechanizm derywacji

Derywacja instancji `Empty[T]` wykorzystuje mechanizm `Mirror.ProductOf[T]` wprowadzony w Scali 3 [39], który umożliwia generyczną introspekcję typów produktowych w czasie komplikacji. Komplilator automatycznie generuje kod konstruujący instancję `T` z wartości domyślnych, weryfikując przy tym ich dostępność.

Przykład użycia

```
1 case class Config( name: String = "default", count: Int = 0,) //  
  Kompilator automatycznie derywuje dla instancji Empty[Config] val empty =  
    summon[Empty[Config]] val instance: Config = empty() //  
    Config("default", 0)
```

Listing 3.19: do konstrukcji instancji z wartościami domyślnymi] Użycie `Empty[T]` do konstrukcji instancji z wartościami domyślnymi

Alternatywy i ich ograniczenia

Bez mechanizmu `Empty[T]` konstrukcja wartości domyślnej w kontekście generycznym wymagałaby od użytkownika jawnego podania domyślnych wartości dla każdego typu `T`, co wyeliminowałoby zalety programowania generycznego.

Mechanizm `Empty[T]` eliminuje te problemy poprzez derywację w czasie komplikacji, zachowując bezpieczeństwo typów oraz zeroowy narzut wykonania.

Ograniczenia

Mechanizm derywacji wymaga, aby:

- typ `T` był typem produktowym (klasa przypadku lub krotka),
- wszystkie parametry konstruktora miały wartości domyślne,
- wartości domyślne były obliczalne w czasie komplikacji.

Naruszenie tych warunków prowadzi do błędu komplikacji z komunikatem wskazującym brakujące wartości domyślne.

3.3.2. ReplaceRefs — transformacja symboli w AST

Klasa `ReplaceRefs` rozszerza `TreeMap` — abstrakcyjną klasę bazową dla transformacji drzew składni abstrakcyjnej w systemie refleksji TASTy [34]. Klasa `TreeMap` definiuje wzorzec projektowy odwiedzającego (*visitor pattern*) [43] dla typowanego AST Scali 3, umożliwiając rekurencyjne przetwarzanie węzłów drzewa z zachowaniem bezpieczeństwa typów.

Motywacja

Podczas ekspansji makr kompilacyjnych często zachodzi potrzeba adaptacji fragmentów kodu z jednego kontekstu leksykalnego do innego. Przykładem jest sytuacja, w której kod oryginalnie odnoszący się do parametru makra `ctx` musi zostać przepisany tak, aby odnosił się do parametru metody w wygenerowanej klasie `newCtx`. Proces ten, znany jako *re-owning* [34], wymaga systematycznej zamiany wszystkich referencji do starego symbolu nowymi referencjami.

Definicja

```
1 private[internal] final class ReplaceRefs[Q <: Quotes](using val quotes: Q)
```

Listing 3.20: Definicja klasy ReplaceRefs rozszerzającej TreeMap

Mechanizm działania

Klasa `ReplaceRefs` implementuje metodę `transformTree`, która:

1. przechodzi rekurencyjnie po wszystkich węzłach drzewa AST,
2. identyfikuje referencje do symboli wymienionych w mapie podstawień,
3. zastępuje te referencje odpowiednimi termami zastępczymi,
4. zachowuje strukturę typów oraz kontekst właściciela symbolu (*owner*).

Transformacja jest realizowana w sposób strukturalnie rekurencyjny, co gwarantuje kompletność zamiany oraz zachowanie poprawności typowania.

Przykład użycia

Poniższy fragment ilustruje zastąpienie referencji do parametru makra `oldCtx` nowym symbolem `newCtx` w ciele wygenerowanej metody:

```
1 // Podczas ekspansji makra:
2 val oldCtxSymbol: Symbol = ... // Symbol parametru makra
3 val newCtxRef: Term = Ref(newCtxSymbol) // Referencja do nowego symbolu
4
5 val replaceRefs = ReplaceRefs()
6 val treeMap = replaceRefs((oldCtxSymbol, newCtxRef))
7
8 // Transformacja tąga funkcji:
9 val originalBody: Term = ... // Tąga funkcji która odnosiła się do oldCtx
10 val transformedBody: Term = treeMap.transformTree(originalBody)(owner)
11 // Wszystkie wystąpienia oldCtxSymbol są teraz zastąpione newCtxRef
```

Listing 3.21: Użycie ReplaceRefs w kontekście ekspansji makra

W rezultacie kod oryginalnie odnoszący się do `oldCtx.field` jest transformowany do `newCtx.field`, co umożliwia prawidłowe działanie wygenerowanego kodu w nowym kontekście leksykalnym.

3.3.3. CreateLambda — programatyczna konstrukcja wyrażeń funkcyjnych

Klasa **CreateLambda** umożliwia programatyczną konstrukcję wyrażeń funkcyjnych (lambda) w czasie komplikacji. W kontekście makr komplikacyjnych bezpośrednie użycie składni lambda języka Scala jest niemożliwe, ponieważ makro operuje na reprezentacjach AST, a nie na kodzie źródłowym [33].

Motywacja

Podczas generacji kodu w makrach często zachodzi potrzeba utworzenia funkcji, której ciało jest konstruowane dynamicznie na podstawie analizy typów lub struktur danych dostępnych w czasie komplikacji. Przykładem jest generacja funkcji transformującej dla parsera, która ekstrahuje wartości z dopasowanych tokenów i konstruuje węzeł AST. Parametry takiej funkcji (symbole tokenów) są znane dopiero w momencie ekspansji makra, co uniemożliwia użycie statycznej składni lambda.

Definicja

```
1 private[internal] final class CreateLambda[Q <: Quotes](using val quotes:  
    Q)
```

Listing 3.22: Definicja klasy `CreateLambda` do programatycznej konstrukcji wyrażeń lambda

Mechanizm działania

Klasa **CreateLambda** implementuje algorytm konstrukcji wyrażeń lambda poprzez:

1. utworzenie świeżego symbolu dla każdego parametru funkcji,
2. wywołanie funkcji użytkownika dostarczającej ciała na podstawie tych symboli,
3. konstrukcję węzła **Lambda** w AST z odpowiednimi typami parametrów i zwracanym,
4. weryfikację typowania wyniku.

Mechanizm ten jest analogiczny do konstrukcji **Lambda** w systemie refleksji TASTy [34], ale oferuje wyższy poziom abstrakcji poprzez automatyczne zarządzanie symbolami i kontekstem właściciela.

Przykład użycia

```
1 val createLambda = CreateLambda()val lambdaExpr: Expr[Int => Int] =  
  createLambda[Int => Int] { case (methodSymbol, List(argTree)) => //  
    Konstrukcja ciała funkcji na podstawie symbolu metody i argumentów  
    buildBody(argTree)}
```

Listing 3.23: Użycie `CreateLambda` do konstrukcji wyrażenia funkcyjnego

3.3.4. Copyable[T] — generyczna funkcja kopiowania

Klasa typu **Copyable[T]** definiuje operację kopiowania (*shallow copy*) dla typów produktowych. W systemie *ALPACA* kopiowanie jest wykorzystywane do tworzenia nowych instancji kontekstu parsera z modyfikowanymi polami (np. aktualizacja numeru wiersza po napotkaniu znaku nowej linii), bez konieczności ręcznej rekonstrukcji całej struktury.

Motywacja

Klasy przypadku w Scali oferują automatycznie generowaną metodę **copy**, która umożliwia tworzenie zmodyfikowanych kopii instancji. Jednak w kontekście programowania generycznego, gdzie typ **T** jest parametrem, dostęp do metody **copy** wymaga refleksji strukturalnej [35], co wprowadza narzut wydajnościowy. Klasa typu **Copyable[T]** rozwiązuje ten problem poprzez derywację funkcji kopiującej w czasie komplikacji, eliminując narzut wykonania.

Definicja

```
1 @implicitNotFound("${T} should be a case class.") private[alpaca] trait
   Copyable[T] extends (T => T)
```

Listing 3.24: definiującej operację kopiowania]Definicja klasy typu **Copyable[T]** definiującej operację kopiowania

Anotacja **@implicitNotFound** dostarcza czytelny komunikat o błędzie w przypadku próby użycia **Copyable[T]** dla typu niebędącego klasą przypadku.

Mechanizm derywacji

Derywacja instancji **Copyable[T]** wykorzystuje mechanizm **Mirror.ProductOf[T]**, który umożliwia dekonstrukcję instancji typu produktowego do krotki wartości pól, a następnie rekonstrukcję nowej instancji z tej krotki. Proces ten jest realizowany w czasie komplikacji bez użycia refleksji w czasie wykonania [39].

Przykład użycia

```
1 case class User( name: String, age: Int,) // Komplikator automatycznie
   derywuje instancji Copyable[User] val copy = summon[Copyable[User]] val
   user = User("Alice", 30) val copied: User = copy(user) // User("Alice",
   30)
```

Listing 3.25: do generycznego kopiowania instancji]Użycie **Copyable[T]** do generycznego kopiowania instancji

Uwaga techniczna

Operacja kopiowania realizowana przez **Copyable[T]** jest kopią płytka (*shallow copy*) — pola będące referencjami do obiektów wskazują na te same instancje w oryginalnej i skopiowanej strukturze. Dla kontekstów parsera, które zawierają głównie typy wartościowe oraz niemodyfikowalne struktury, ograniczenie to nie stanowi problemu.

Analiza wydajności

Teoretycznie, operacja kopiowania realizowana przez **Copyable[T]** powinna być równoważna wywołaniu metody **copy**, ponieważ obie sprowadzają się do konstrukcji nowej instancji z tych samych wartości pól. W praktyce **Copyable[T]** eliminuje narzut związany z refleksją strukturalną, który występowałby przy dostępie do **copy** w kontekście generycznym.

Empiryczna weryfikacja tego założenia wykracza poza zakres niniejszej pracy. W kontekście systemu *ALPACA* korzyść z unifikacji interfejsu (klasa typu) przewyższa potencjalne różnice wydajnościowe, które są pomijalnie małe dla operacji kopiowania struktur o niewielkim rozmiarze (kilka pól).

3.3.5. Porównanie z istniejącymi bibliotekami

Ekosystem Scali oferuje biblioteki dedykowane programowaniu generycznemu, takie jak Shapeless [44] i Magnolia [45], które realizują derywację klas typów dla typów produktowych i sumarycznych. Wybór własnej implementacji narzędzi **Empty[T]** i **Copyable[T]** w systemie *ALPACA* wynikał z następujących przesłanek:

Minimalizacja zależności

Biblioteki takie jak Shapeless wprowadzają znaczące zależności oraz wydłużają czas komplikacji ze względu na złożone mechanizmy derywacji oparte na typach zależnych. Dla projektu o wąskim zakresie funkcjonalności koszt ten jest nieuzasadniony.

Wykorzystanie natywnych mechanizmów Scali 3

Scala 3 wprowadza mechanizm **Mirror** [39], który eliminuje potrzebę stosowania makr w stylu Shapeless, redukując złożoność implementacji. Własna implementacja oparta na **Mirror** jest prostsza, bardziej czytelna oraz lepiej wspierana przez narzędzia IDE niż rozwiązania oparte na starszych mechanizmach metaprogramowania.

Kontrola nad komunikatami błędów

Biblioteki generyczne generują często nieczytelne komunikaty błędów związane z wewnętrznymi abstrakcjami. Własna implementacja pozwala dostosować komunikaty błędów do kontekstu systemu *ALPACA*.

Bibliografia

- [1] A. V. Aho, M. S. Lam, R. Sethi i J. D. Ullman. *Compilers: Principles, Techniques, and Tools*. 2 wyd. Addison-Wesley, 2006.
- [2] J. E. Hopcroft, R. Motwani i J. D. Ullman. *Introduction to Automata Theory, Languages, and Computation*. 3 wyd. Addison-Wesley, 2006.
- [3] N. Chomsky. „Three models for the description of language”. W: *IRE Transactions on Information Theory* 2.3 (1956), s. 113–124.
- [4] K. Thompson. „Programming Techniques: Regular expression search algorithm”. W: *Communications of the ACM* 11.6 (1968), s. 419–422.
- [5] P. M. Lewis II i R. E. Stearns. „Syntax-directed transduction”. W: *Journal of the ACM* 15.3 (1968), s. 465–488.
- [6] D. E. Knuth. „On the translation of languages from left to right”. W: *Information and Control* 8.6 (1965), s. 607–639.
- [7] M. E. Lesk i E. Schmidt. *Lex: A lexical analyzer generator*. T. 39. Bell Laboratories Murray Hill, NJ, 1975.
- [8] S. C. Johnson i in. *Yacc: Yet another compiler-compiler*. T. 32. Bell Laboratories Murray Hill, NJ, 1975.
- [9] T. Parr, P. Wells, R. Klaren, L. Craymer, J. Coker, S. Stanchfield, J. Mitchell i C. Flack. *What's ANTLR*. 2004.
- [10] D. Beazley. *PLY (Python Lex-Yacc)*. 2005. URL: <https://www.dabeaz.com/ply/ply.html> (term. wiz. 19.03.2025).
- [11] D. Beazley. *SLY (Sly Lex-Yacc)*. 2016. URL: <https://sly.readthedocs.io/en/latest/sly.html> (term. wiz. 19.03.2025).
- [12] D. Beazley. *SLY Github*. URL: <https://github.com/dabeaz/sly> (term. wiz. 19.03.2025).
- [13] A. Moors, F. Piessens i M. Odersky. „Parser combinators in Scala”. W: *CW Reports* (2008).
- [14] *scala-parser-combinators Getting Started*. URL: https://github.com/scala/scala-parser-combinators/blob/main/docs/Getting_Started.md (term. wiz. 04.04.2025).
- [15] J. Boyland i D. Spiewak. „Tool paper: ScalaBison recursive ascent-descent parser generator”. W: *Electronic Notes in Theoretical Computer Science* 253.7 (2010).
- [16] A. A. Myltsev. „Parboiled2: A macro-based approach for effective generators of parsing expressions grammars in Scala”. W: *arXiv preprint arXiv:1907.03436* (2019).

- [17] L. Haoyi. *sfscala.org: Li Haoyi, FastParse: Fast, Programmable, Modern Parser-Combinators in Scala*. 2015.
- [18] *FastParse Getting Started*. URL: <https://com-lihaoyi.github.io/fastparse/#GettingStarted> (term. wiz. 04. 04. 2025).
- [19] L. Haoyi. *FastParse. Fast, Modern Parser Combinators*. URL: <https://www.lihaoyi.com/post/slides/FastParse.pdf> (term. wiz. 18. 04. 2025).
- [20] *Dropped: Scala 2 Macros. Scala 3 Reference*. URL: <https://docs.scala-lang.org/scala3/reference/metaprogramming/migrating/macros-compatibility.html> (term. wiz. 25. 10. 2025).
- [21] *Metaprogramming. Scala 3 Reference*. URL: <https://docs.scala-lang.org/scala3/reference/metaprogramming.html> (term. wiz. 25. 10. 2025).
- [22] N. Stucki. *Scalable Metaprogramming in Scala 3*. EPFL Infoscience page. 2024. URL: <https://infoscience.epfl.ch/entities/publication/6dd02f9b-1f9b-4c9c-9748-ddf1634c1630> (term. wiz. 25. 10. 2025).
- [23] N. Stucki, A. Biboudis, S. Doeraene i M. Odersky. „Semantics-preserving inlining for metaprogramming”. W: *Proceedings of the 11th ACM SIGPLAN International Symposium on Scala*. 2020. DOI: [10.1145/3426426.3428486](https://doi.org/10.1145/3426426.3428486). URL: <https://dl.acm.org/doi/10.1145/3426426.3428486>.
- [24] N. Stucki. „Scalable Metaprogramming in Scala 3”. Prac. dokt. Lausanne: EPFL, 2020.
- [25] *Runtime Multi-Stage Programming. Scala 3 Reference*. URL: <https://docs.scala-lang.org/scala3/reference/metaprogramming/staging.html> (term. wiz. 25. 10. 2025).
- [26] N. Stucki, J. Brachthäuser i M. Odersky. „A practical unification of multi-stage programming and macros”. W: *Proceedings of the 9th ACM SIGPLAN International Symposium on Scala*. 2018. DOI: [10.1145/3278122.3278139](https://doi.org/10.1145/3278122.3278139). URL: <https://dl.acm.org/doi/10.1145/3278122.3278139>.
- [27] N. Stucki, A. Biboudis i M. Odersky. „Multi-stage programming with generative and analytical macros”. W: *Proceedings of the 12th ACM SIGPLAN International Symposium on Scala*. 2021. DOI: [10.1145/3486609.3487203](https://doi.org/10.1145/3486609.3487203). URL: <https://dl.acm.org/doi/10.1145/3486609.3487203>.
- [28] *Reflection. Scala 3 Reference*. URL: <https://docs.scala-lang.org/scala3/reference/metaprogramming/reflection.html> (term. wiz. 25. 10. 2025).
- [29] *Quoted Code / Macros in Scala 3*. URL: <https://docs.scala-lang.org/scala3/guides/macros/quotes.html> (term. wiz. 25. 10. 2025).
- [30] N. Stucki, A. Biboudis, S. Doeraene i M. Odersky. „Semantics-preserving inlining for metaprogramming”. W: SCALA 2020 (2020), s. 14–24. DOI: [10.1145/3426426.3428486](https://doi.org/10.1145/3426426.3428486). URL: <https://doi.org/10.1145/3426426.3428486>.
- [31] Y. Lilis i A. Savidis. *A Survey of Metaprogramming Languages*. Paź. 2019. DOI: [10.1145/3354584](https://doi.org/10.1145/3354584). URL: <https://doi.org/10.1145/3354584>.
- [32] *Macros. Scala 3 Reference*. URL: <https://docs.scala-lang.org/scala3/reference/metaprogramming/macros.html> (term. wiz. 25. 10. 2025).

-
- [33] *Scala 3 Macros*. URL: <https://docs.scala-lang.org/scala3/guides/macros/macros.html> (term. wiz. 25.10.2025).
 - [34] *Reflection / Macros in Scala 3*. URL: <https://docs.scala-lang.org/scala3/guides/macros/reflection.html> (term. wiz. 25.10.2025).
 - [35] *Selectable / Macros in Scala 3*. URL: <https://docs.scala-lang.org/scala3/reference/changed-features/structural-types.html> (term. wiz. 27.11.2025).
 - [36] *Computed Field Names / Macros in Scala 3*. URL: <https://docs.scala-lang.org/scala3/reference/other-new-features/named-tuples.html#:~:text=Computed%20Field%20Names> (term. wiz. 27.11.2025).
 - [37] T. Lindholm, F. Yellin, G. Bracha i A. Buckley. *The Java Virtual Machine Specification, Java SE 8 Edition*. Java SE 8. Specyfikacja JVM definiuje limit rozmiaru kodu bajtowego metody na 65536 bajtów. Addison-Wesley Professional, 2014.
 - [38] B. Kozak. *Method too large*. URL: <https://halotukozak.github.io/posts/scala-macro-jvm-method-size-limit/> (term. wiz. 27.11.2025).
 - [39] *Type Class Derivation / Scala 3 Reference*. URL: <https://docs.scala-lang.org/scala3/reference/contextual/derivation.html> (term. wiz. 29.11.2025).
 - [40] E. Burmako. „Scala Macros: Let Our Powers Combine!” W: *Proceedings of the 4th Workshop on Scala*. 2013. DOI: [10.1145/2489837.2489840](https://doi.org/10.1145/2489837.2489840). URL: <https://dl.acm.org/doi/10.1145/2489837.2489840>.
 - [41] B. C. Pierce. *Types and Programming Languages*. Cambridge, Massachusetts: MIT Press, 2002.
 - [42] M. Odersky, P. Altherr, V. Cremet, B. Emir, S. Maneth, S. Micheloud, N. Mihaylov, M. Schinz, E. Stenman i M. Zenger. *An Overview of the Scala Programming Language*. Spraw. tech. IC/2004/64. EPFL, 2004. URL: <https://lampwww.epfl.ch/~odersky/papers/ScaleOverview.pdf>.
 - [43] E. Gamma, R. Helm, R. Johnson i J. Vlissides. *Design Patterns: Elements of Reusable Object-Oriented Software*. Addison-Wesley Professional, 1994.
 - [44] *Shapeless: Generic programming for Scala*. URL: <https://github.com/milessabin/shapeless> (term. wiz. 29.11.2025).
 - [45] B. Kozak. *Method too large*. URL: <https://halotukozak.github.io/posts/scala-macro-jvm-method-size-limit/> (term. wiz. 27.11.2025).

Spis rysunków

Spis tabel

| | |
|-----------------------------------------------------------------------------------------------------|----|
| 1.1 Porównanie wybranych narzędzi do generowania analizatorów leksykalnych i składniowych | 13 |
|-----------------------------------------------------------------------------------------------------|----|

Spis algorytmów

Spis listingów

| | | |
|------|---------------------------------------------------------------------------------------------|----|
| 1.1 | Fragment definicji parsera Ruby w technologii Yacc | 7 |
| 1.2 | Fragment definicji parsera w Pythonie, wykorzystujący bibliotekę SLY | 9 |
| 1.3 | Fragment niedziałającego kodu w Pythonie, wykorzystujący bibliotekę SLY | 10 |
| 1.4 | Przykładowy komunikat błędu w bibliotece <i>SLY</i> | 10 |
| 1.5 | Fragment błędu wygenerowanego przez bibliotekę <i>parboiled2</i> | 11 |
| 3.1 | Definicja typu <i>LexerDefinition</i> | 17 |
| 3.2 | Punkt wejścia: transparent inline def lexer | 17 |
| 3.3 | Dekonstrukcja funkcji częściowej (dopasowanie AST do <i>CaseDef</i>) | 18 |
| 3.4 | Zastąpienie referencji starego kontekstu nowymi (ReplaceRefs) | 18 |
| 3.5 | Funkcja <i>extractSimple</i> : dopasowywanie definicji tokenów | 19 |
| 3.6 | Rafinowanie typu wynikowego o pola tokenów | 21 |
| 3.7 | Wynikowy typ leksera | 21 |
| 3.8 | Tworzenie typuFields | 22 |
| 3.9 | Podejście oparte na mapowaniu dynamicznym | 23 |
| 3.10 | Podejście oparte na jawnej definicji klasy | 24 |
| 3.11 | Klasa bazowa Parser | 25 |
| 3.12 | Przykład definicji reguł parsera | 25 |
| 3.13 | Naiwna implementacja prowadząca do przekroczenia limitu | 26 |
| 3.14 | Rozwiążanie problemu rozmiaru metod przez fragmentację | 27 |
| 3.15 | Tworzenie akcji semantycznej z zachowaniem referencji | 28 |
| 3.16 | Deklaracja rozwiązań konfliktów | 28 |
| 3.17 | Implementacja <i>ToExpr</i> dla <i>ParseTable</i> | 29 |
| 3.18 | Definicja klasy typu <i>Empty[T]</i> | 30 |
| 3.19 | Użycie <i>Empty[T]</i> | 31 |
| 3.20 | Definicja klasy <i>ReplaceRefs</i> rozszerzającej <i>TreeMap</i> | 32 |
| 3.21 | Użycie <i>ReplaceRefs</i> w kontekście ekspansji makra | 32 |
| 3.22 | Definicja klasy <i>CreateLambda</i> do programatycznej konstrukcji wyrażeń lambda | 33 |
| 3.23 | Użycie <i>CreateLambda</i> do konstrukcji wyrażenia funkcyjnego | 33 |
| 3.24 | Definicja klasy typu <i>Copyable[T]</i> | 34 |
| 3.25 | Użycie <i>Copyable[T]</i> | 34 |