



Akademia Górniczo-Hutnicza im. Stanisława Staszica w Krakowie

Wydział Informatyki

Projekt dyplomowy

*Implementacja narzędzi lex i yacc z wykorzystaniem
metaprogramowania*

*Implementation of lexical analyzer (lex) and parser generator
(yacc) tools using metaprogramming techniques*

Autorzy:	Bartosz Buczek, Bartłomiej Kozak
Kierunek studiów:	Informatyka
Opiekun pracy:	dr inż. Tomasz Służalec

Kraków, 2025

Spis treści

1	Cel prac i wizja projektu	5
1.1	Charakterystyka problemu	5
1.2	Motywacja projektu	5
1.3	Przegląd istniejących rozwiązań	6
1.3.1	Lex, Yacc	6
1.3.2	PLY, SLY	7
1.3.3	ANTLR	8
1.3.4	Scala parser combinators	9
1.3.5	ScalaBison	9
1.3.6	parboiled2	9
1.3.7	FastParse	10
1.3.8	Podsumowanie	10
2	Metaprogramowanie w Scali 3	12
2.1	Wprowadzenie	12
2.1.1	Quotes i Splices	12
2.1.2	Bezpieczeństwo międzyetapowe	12
2.2	Mechanizmy metaprogramowania w Scali 3	13
2.2.1	Definicje inline	13
2.2.2	Makra oparte na wyrażeniach	13
2.2.3	Dopasowanie wzorców kodu	13
2.2.4	Refleksja TASTy	13
3	Implementacja	14
3.1	Praktyczna implementacja analizatora leksykalnego z wykorzystaniem makr w Scali 3	14
3.1.1	Wprowadzenie do studium przypadku	14
3.1.2	Architektura systemu leksera	14
3.1.3	Analiza drzewa składni abstrakcyjnej	15
3.1.4	Transformacja i adaptacja referencji	15
3.1.5	Ekstrakcja i kompilacja wzorców	16
3.1.6	Analiza wzorców: klasa CompileNameAndPattern	16
3.1.7	Generacja klasy anonimowej	17
3.1.8	Walidacja i obsługa błędów	19
3.2	Praktyczna implementacja generatora parserów z wykorzystaniem makr w Scali 3	19
3.2.1	Wprowadzenie do generatora parserów	19
3.2.2	Interfejs API parsera	19

3.2.3	Generacja tabel parsowania w czasie kompilacji	20
3.2.4	Trudne problemy rozwiązane w implementacji	21
3.2.5	Generacja kodu tabel	24
3.2.6	Podsumowanie implementacji parsera	25
Spis rysunków		28
Spis tabel		29
Spis algorytmów		30
Spis listingów		31

Rozdział 1

Cel prac i wizja projektu

1.1. Charakterystyka problemu

Leksery i parsery są kluczowymi elementami w procesie tworzenia interpreterów i kompilatorów języków programowania. Pozwalają one przekształcić kod źródłowy napisany przez programistę na reprezentację wewnętrzną, wykorzystywaną później przez dalsze etapy przetwarzania kodu.

Analiza leksykalna wykonywana przez lekser polega na rozdzieleniu kodu źródłowego na jednostki logiczne, zwane leksemami. Parser natomiast wykonuje analizę składniową w celu ustalenia struktury gramatycznej tekstu i jej zgodności z gramatyką języka.

Celem pracy inżynierskiej jest stworzenie narzędzia *ALPACA* (Another Lexer Parser And Compiler Alpaca) w języku Scala, które implementuje funkcjonalności powszechnie stosowane w budowie lekserów i parserów.

1.2. Motywacja projektu

Projekt ma na celu stworzenie nowoczesnego narzędzia do generowania lekserów i parserów w języku Scala, łączącego zalety istniejących rozwiązań z nowoczesnym podejściem technologicznym. Jego główne cele to:

1. Stworzenie intuicyjnego API.
2. Opracowanie obszernej dokumentacji.
3. Rozbudowana diagnostyka błędów.
4. Poprawa wydajności względem rozwiązań w języku Python.
5. Integracja z popularnymi środowiskami programistycznymi (IDE).

Proponowane rozwiązanie łączy nowoczesne podejście technologiczne z praktycznym zastosowaniem w edukacji i programowaniu. Może on służyć jako narzędzie dydaktyczne, ułatwiając naukę teorii kompilacji, w pracach badawczych, a także jako kompleksowe narzędzie do tworzenia praktycznych rozwiązań.

1.3. Przegląd istniejących rozwiązań

Dostępne na rynku rozwiązania umożliwiają tworzenie analizatorów, jednak charakteryzują się ograniczeniami związanymi z wydajnością, wysokim progiem wejścia i diagnostyką błędów.

1.3.1. Lex, Yacc

Lex[1] i *Yacc*[2] to klasyczne, dobrze ugruntowane narzędzia, które odegrały kluczową rolę w tworzeniu setek współczesnych języków programowania. Definicja leksera i parsera w tych systemach odbywa się poprzez specjalnie zaprojektowaną składnię konfiguracyjną. Mimo pewnych zalet, jego złożoność i wysoki próg wejścia mogą stanowić wyzwanie.

Ponieważ *Lex* i *Yacc* zostały zaprojektowane do współpracy z językiem C, ich integracja z nowoczesnymi językami programowania bywa utrudniona. Rozszerzanie tych narzędzi o dodatkowe, specyficzne funkcjonalności jest skomplikowane, co ogranicza ich elastyczność. Brak wsparcia dla współczesnych środowisk programistycznych (IDE) dodatkowo obniża komfort użytkowania w porównaniu z nowoczesnymi alternatywami.

```

1 {
2  /*%%*/
3  value_expr($3);
4  $1->nd_value = $3;
5  $$ = $1;
6  /*%
7  $$ = dispatch2(massign, $1, $3);
8  %*/
9  }
10 | var_lhs tOP_ASGN command_call
11 {
12  value_expr($3);
13  $$ = new_op_assign($1, $2, $3);
14  }
15 | primary_value '[' opt_call_args rbracket tOP_ASGN command_call
16 {
17  /*%%*/
18  NODE *args;
19
20  value_expr($6);
21  if (!$3) $3 = NEW_ZARRAY();
22  args = arg_concat($3, $6);
23  if ($5 == tOROP) {
24    $5 = 0;
25  }
26  else if ($5 == tANDOP) {
27    $5 = 1;
28  }
29  $$ = NEW_OP_ASGN1($1, $5, args);
30  fixpos($$, $1);
31  /*%
32  $$ = dispatch2(aref_field, $1, escape_Qundef($3));
33  $$ = dispatch3(opassign, $$, $5, $6);
34  %*/
35  }

```

Listing 1.1: Fragment definicji parsera Ruby w technologii Yacc

1.3.2. PLY, SLY

PLY[3] i jego nowszy odpowiednik *SLY*[4] to biblioteki inspirowane narzędziami Lex i Yacc. Oferują elastyczne podejście do budowy parserów, umożliwiając samodzielną implementację obsługi leksemów, budowę drzewa AST, czy dodatkowe funkcjonalności takie jak obliczanie numeru linii w lekserze.

Głównym ograniczeniem PLY i SLY jest implementacja w języku Python. Ze względu na interpretowany charakter oraz dynamiczne typowanie, parsery te charakteryzują się niską wydajnością, a brak statycznego typowania utrudnia wykrywanie błędów na etapie kompilacji. Przy implementacji parserów z użyciem biblioteki SLY w środowisku PyCharm obserwuje się wiele ostrzeżeń dotyczących potencjalnych naruszeń reguł, co często wymaga zastosowania mechanizmów supresji, aby uniknąć fałszywie pozytywnych wyników analizy statycznej kodu. Ponadto należy zaznaczyć, iż autor projektu informuje o braku dalszego rozwoju tych narzędzi[5].

Przykład 1.2 ilustruje kilka nieintuicyjnych, automatycznych mechanizmów obecnych w bibliotece *SLY*.

- Operator `@()` jest zdefiniowany, aby automatycznie analizować tekst przy pomocy wyrażeń regularnych. Literały muszą być zawarte w cudzysłowie, a „zmienna” odpowiada za matchowany „typ”.
- Nazwa metody oznacza „typ” zwracany przez daną produkcję, czyli dla definicji **IF** należy najpierw odszukać wszystkie metody, które mają nazwę **condition**, gdyż są to możliwe produkcje.
- W krotce (sic!) **precedence** definiujemy pierwszeństwo operatorów, jednakże dodanie **% prec** pozwala nadpisać priorytet dla konkretnej reguły składniowej.
- Argument **p** pozwala na dostęp do kontekstu produkcji (np. numeru linii), ale także do zmiennych w patternu match w adnotacji. Jeśli zdefiniowany jest więcej niż jeden, to dodajemy numer do accesora, np. **expr1** jest odwołaniem się do drugiego wyrażenie **expr**. Jednocześnie, można to zrobić także poprzez odwołanie się do konkretnego indeksu obiektu **p**.

```

1 class MatrixParser(Parser):
2     tokens = MatrixScanner.tokens
3
4     precedence = (
5         ('nonassoc', 'IFX'),
6         ('nonassoc', 'ELSE'),
7         ('nonassoc', 'EQUAL'),
8     )
9
10    @_('{" instructions }"')
11    def block(self, p: YaccProduction):
12        raise NotImplementedError
13
14    @_('instruction')
15    def block(self, p: YaccProduction):
16        raise NotImplementedError
17
18    @_('IF "(" condition ")" block %prec IFX')
19    def instruction(self, p: YaccProduction):

```

```

20     raise NotImplementedError
21
22 @_('IF "(" condition ")" block ELSE block')
23 def instruction(self, p: YaccProduction):
24     raise NotImplementedError
25
26 @_('expr EQUAL expr')
27 def condition(self, p: YaccProduction):
28     args = [p.expr0, p.expr1]
29     raise NotImplementedError

```

Listing 1.2: Fragment definicji parsera w Pythonie, wykorzystujący bibliotekę *SLY*

Komunikaty błędów w bibliotece *SLY* są bardzo ograniczone, co obrazuje przykład 1.3, który po uruchomieniu informuje użytkownika błędem z fragmentu kodu `??`. Okazuje się, że problemem był brak atrybutu `ignore_comment` w definicji `Lexer`.

```

1 tokens = Scanner().tokenize("a = 1 + 2")
2 for tok in tokens:
3     print(tok)

```

Listing 1.3: Fragment niedziałającego kodu w Pythonie, wykorzystujący bibliotekę *SLY*

```

1 File "main.py", line 2, in <module>
2     for tok in tokens:
3         ^^^^^^
4 File "Python\site-packages\sly\lex.py", line 374, in tokenize
5     _set_state(type(self))
6     ~~~~~^~~~~~
7 File "Python\site-packages\sly\lex.py", line 367, in _set_state
8     _master_re = cls._master_re
9                 ^^^^^^^^^^^^^^^
10 AttributeError: type object 'Scanner' has no attribute '_master_re'

```

Listing 1.4: Przykładowy komunikat błędu w bibliotece *SLY*

1.3.3. ANTLR

ANTLR[6] to kolejne rozwiązanie inspirowane narzędziami *Lex* i *Yacc*, oferujące zaawansowane mechanizmy analizy składniowej. Jego twórcy opracowali dedykowany język DSL, znany jako Grammar v4, który umożliwia definiowanie składni analizowanego języka. Na podstawie tej definicji *ANTLR* generuje parser w wybranym przez użytkownika języku programowania, takim jak Python, Java, C++ lub JavaScript.

Wspomaganie pracy z *ANTLR* w znacznym stopniu ułatwiają dedykowane wtyczki do środowisk Visual Studio Code oraz IntelliJ IDEA. Oferują one funkcjonalności, takie jak kolorowanie składni, autouzupełnianie kodu, nawigację do definicji leksemów oraz walidację błędów, co znacząco przyspiesza proces tworzenia parserów.

Jedną z kluczowych różnic *ANTLR* w porównaniu do innych narzędzi jest wykorzystanie gramatyki *LL(*)*, podczas gdy klasyczne rozwiązania, takie jak *Yacc* czy *SLY*, implementują *LALR(1)*. *LL(*)* jest bardziej intuicyjna i czytelna dla programistów, co ułatwia definiowanie reguł składniowych. Jednakże, jej zastosowanie wiąże się z większym zużyciem pamięci oraz niższą wydajnością w porównaniu do *LALR(1)*.

Dodatkowym wyzwaniem podczas korzystania z *ANTLR* jest konieczność nauki składni DSL Grammar v4 oraz ograniczenie wsparcia dla narzędzi deweloperskich. Pełne wykorzystanie możliwości *ANTLR* wymaga korzystania z jednego z dedykowanych środowisk, co może stanowić istotne ograniczenie dla użytkowników preferujących inne IDE.

1.3.4. Scala parser combinators

Biblioteka *Scala parser combinators*[7] była popularnym sposobem na tworzenie parserów, lecz jak wynika z dokumentacji, „Trudno jest jednak zrozumieć ich działanie i jak zacząć. Po skompilowaniu i uruchomieniu kilku pierwszych przykładów, mechanizm działania staje się bardziej zrozumiały, ale do tego czasu może to być zniechęcające, a standardowa dokumentacja nie jest zbyt pomocna”[8].

1.3.5. ScalaBison

Z podsumowania artykułu na temat *ScalaBison*[9] wiadomo, że to praktyczny generator parserów dla języka Scala oparty na technologii rekurencyjnego wstępowania i zstępowania, który akceptuje pliki wejściowe w formacie *bison*. Parsery generowane przez *ScalaBison* używają bardziej informacyjnych komunikatów o błędach niż te generowane przez pierwowzór *bison*, a także szybkość parsowania i wykorzystanie miejsca są znacznie lepsze niż *scala-combinators*, ale są nieco wolniejsze niż najszybsze generatory parserów oparte na JVM.

Dodatkowo należy zaznaczyć, iż jest to rozwiązanie już niewspierane i stworzone w celach akademickich. Korzysta z przestarzałej wersji Scali, nie posiada wyczerpującej dokumentacji i liczba funkcjonalności jest bardzo ograniczona w porównaniu do np. technologii *SLY*.

1.3.6. parboiled2

parboiled2[10] to biblioteka w Scali umożliwiająca lekkie i szybkie parsowanie dowolnego tekstu wejściowego. Implementuje ona oparty na makrach generator parsera dla gramatyk wyrażeń parsujących (PEG), który działa w czasie kompilacji i tłumaczy definicję reguły gramatycznej na odpowiadający jej bytecode JVM. Niestety próg wejścia ze względu na skomplikowany i nieintuicyjny DSL jest wysoki. Zgodnie z przykładem 1.5, raportowanie błędów jest bardzo ograniczone (problem z implementacją wynika jedynie z różnic w liczbie parametrów funkcji).

```

1 [error] /Users/haoyi/Dropbox (Personal)/Workspace/scala-js-book/scalateXApi
   /src/main/scala/scalateX/stages/Parser.scala:60: overloaded
2 method value apply with alternatives:
3 [error] [I, J, K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z, RR](f: (I, J
   , K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z, scalateX.stages.Ast.
   Block.
4 Text, scalateX.stages.Ast.Chain, Int, scalateX.stages.Ast.Block) => RR)(
   implicit j: org.parboiled2.support.ActionOps.SJoin[shapeless.::[I,
5 shapeless.::[J, shapeless.::[K, shapeless.::[L, shapeless.::[M, shapeless.::[N,
   shapeless.::[O, shapeless.::[P, shapeless.::[Q, shapeless.::[R,
6 shapeless.::[S, shapeless.::[T, shapeless.::[U, shapeless.::[V, shapeless.::[W,
   shapeless.::[X, shapeless.::[Y, shapeless.::[Z, shapeless.

```

```

7 HNil]]]]]]]]]]]]]]]]]]],shapeless.HNil,RR], implicit c: org.parboiled2.
  support.FCapture[(I, J, K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z,
    scalatex.
8 stages.Ast.Block.Text, scalatex.stages.Ast.Chain, Int, scalatex.stages.Ast.
  Block) => RR])org.parboiled2.Rule[j.In,j.Out] <and>
9 [error] [J, K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z, RR](f: (J, K, L
  , M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z, scalatex.stages.Ast.Block.
    Text,
10 scalatex.stages.Ast.Chain, Int, scalatex.stages.Ast.Block) => RR)(implicit
  j: org.parboiled2.support.ActionOps.SJoin[shapeless.:[J,
11 shapeless.:[K,shapeless.:[L,shapeless.:[M,shapeless.:[N,shapeless.:[O,
  shapeless.:[P,shapeless.:[Q,shapeless.:[R,shapeless.:[S,
12 shapeless.:[T,shapeless.:[U,shapeless.:[V,shapeless.:[W,shapeless.:[X,
  shapeless.:[Y,shapeless.:[Z,shapeless.HNil]]]]]]]]]]]]]]]]],shapeless.
  HNil,RR], implicit c: org.parboiled2.support.FCapture[(J, K, L, M, N, O,
    P, Q, R, S,
13 T, U, V, W, X, Y, Z, scalatex.stages.Ast.Block.Text, scalatex.stages.Ast.
  Chain, Int, scalatex.stages.Ast.Block) => RR])org.parboiled2.Rule[j.
14 In,j.Out] <and>

```

Listing 1.5: Niewielki fragment (14 z 133 linii) błędu wygenerowanego przez bibliotekę *parboiled2*, który pochodzi z prezentacji Li Haoyi na temat *FastParse*[11].

1.3.7. FastParse

FastParseFastParse[12] to opracowana przez Li Haoyi, wysokowydajna biblioteka kombinatorów parserów dla Scali, zaprojektowana w celu uproszczenia tworzenia parserów tekstu strukturalnego. Umożliwia ona programistom definiowanie parserów rekurencyjnych, dzięki czemu nadaje się do parsowania języków programowania, formatów danych, takich jak JSON, czy DSL-i. Cechą charakterystyczną *FastParse* jest równowaga między użytecznością a wydajnością. Parsery są konstruowane poprzez łączenie mniejszych parserów za pomocą operatorów, takich jak \sim dla sekwencjonowania i $|$ dla alternatyw, przy jednoczesnym zachowaniu czytelności zbliżonej do formalnych definicji gramatyki. Według dokumentacji[12], parsery *Fastparse* zajmują 1/10 kodu w porównaniu do ręcznie napisanego parsera rekurencyjnego. W porównaniu do narzędzi generujących parsery, takich jak *ANTLR* lub *Lex* i *Yacc*, implementacja nie wymaga żadnego specjalnego kroku kompilacji lub generowania kodu. To sprawia, że rozpoczęcie pracy z *Fastparse* jest znacznie łatwiejsze niż w przypadku bardziej tradycyjnych narzędzi do generowania parserów. Przykładowo, parser wyrażeń arytmetycznych może być zwięźle napisany, aby obsługiwać zagnieżdżone nawiasy, pierwszeństwo operatorów i raportowanie błędów w mniej niż 20 liniach kodu[13]. Biblioteka kładzie również nacisk na debugowanie, generując szczegółowe komunikaty o błędach, które wskazują dokładną lokalizację i przyczynę niepowodzeń parsowania, takich jak niedopasowane nawiasy lub nieprawidłowe tokeny.

1.3.8. Podsumowanie

Narzędzie	Lex&Yacc	PLY/SLY	ANTLR	scala-bison
Język implementacji	C	Python	Java	Scala (nad Bisonem)
Język użycia	regex, BNF, akcje w C	DSL	DSL oparty na EBNF	BNF, akcje w Scali
Wydajność	wysoka	niska	umiarkowana	wysoka
Łatwość użycia	średnia	umiarkowana	wysoka	średnia
Aktywne wsparcie	brak	nie	tak	nie
Diagnostyka błędów	słaba	średnia	dobra	słaba
Dokumentacja	dobra	średnia, nieaktualna	dobra	słaba
Popularność	wysoka	średnia	wysoka	niska
Integracja IDE	nieoficjalny plugin	ograniczona	oficjalny plugin	brak
Wsparcie do debugowania	brak	dobrze	częściowe	dobrze
Generowania kodu	nie	nie	tak	nie
Narzędzie	Scala parser combinators	parboiled2	FastParse	ALPACA
Język implementacji	Scala	Scala	Scala	Scala
Język użycia	DSL w Scali	DSL w Scali	DSL w Scali	Scala
Wydajność	wysoka	umiarkowana	wysoka	TODO
Łatwość użycia	niska	średnia	średnia	TODO
Aktywne wsparcie	nie	nie	tak	TODO
Diagnostyka błędów	dobra	niska	dobra	TODO
Dokumentacja	słaba	bardzo dobra	bardzo dobra	TODO
Popularność	średnia	niska	rosnąca	TODO
Integracja IDE	wsparcie dla Scali	wsparcie dla Scali	wsparcie dla Scali	TODO
Wsparcie do debugowania	dobrze	dobrze	dobrze	TODO
Generowania kodu	nie	nie	nie	TODO

Tabela 1.1: Porównanie wybranych narzędzi do generowania lekserów i parserów

Rozdział 2

Metaprogramowanie w Scali 3

2.1. Wprowadzenie

Scala 3, znana również jako Dotty, wprowadza całkowicie przeprojektowany system metaprogramowania, stanowiący fundamentalną zmianę w stosunku do eksperymentalnych makr dostępnych w Scali 2[14, 15].

Metaprogramowanie w Scali 3 zostało zaprojektowane z naciskiem na bezpieczeństwo typów, przenośność oraz skalowalność, oferując programistom możliwość generowania i analizowania kodu w czasie kompilacji przy zachowaniu pełnej ekspresywności języka[16, 17]. W przeciwieństwie do poprzedniego systemu, który eksponował wewnętrzne mechanizmy kompilatora i był źródłem problemów z kompatybilnością między wersjami[18], nowy system metaprogramowania jest zaprojektowany jako stabilny i przenośny interfejs programistyczny. Podstawą teoretyczną systemu metaprogramowania w Scali 3 jest programowanie wieloetapowe (ang. *multi-stage programming*), paradygmat pozwalający na odróżnienie różnych etapów wykonania programu[19, 18]. W tym modelu kod może być wykonywany w różnych fazach: w czasie kompilacji (ang. *compile-time*) lub w czasie wykonania (ang. *runtime*)[19].

2.1.1. Quotes i Splices

Kluczowymi koncepcjami w systemie metaprogramowania Scali 3 są *quotes* i *splices*[20, 21]. *Quotes*, oznaczane jako `'{ ... }`, służą do opóźnienia wykonania kodu i traktowania go jako danych[22, 23]. *Splices*, oznaczane jako ``${ ... }`, pozwalają na ocenę wyrażenia generującego kod i wstawienie wyniku do otaczającego kontekstu[22, 23, 24].

Formalna semantyka tych konstrukcji została przedstawiona w pracy Stuckiego, Brachthäusera i Odersky'ego[21], gdzie *quotes* i *splices* są traktowane jako prymitywne formy w typowanych drzewach składniowych (ang. *typed abstract syntax trees*). Autorzy dowodzą, że system zachowuje bezpieczeństwo typów oraz higieniczność, zapewniając, że wygenerowany kod nie może przypadkowo powiązać identyfikatorów z niewłaściwymi zmiennymi[21].

2.1.2. Bezpieczeństwo międzyetapowe

Scala 3 gwarantuje bezpieczeństwo międzyetapowe (ang. *cross-stage safety*) poprzez sprawdzanie poziomów etapowania w czasie kompilacji[18, 21]. Zmienne lokalne mogą być

używane tylko na tym samym poziomie etapowania, na którym zostały zdefiniowane, co zapobiega dostępowi do zmiennych, które jeszcze nie istnieją lub już nie są dostępne[18].

System również zapewnia, że typy generyczne używane w wyższym poziomie etapowania niż ich definicja wymagają instancji klasy typu `Type[T]`, która niesie reprezentację typu niepoddaną wymazywaniu (ang. *type erasure*)[18]. To podejście rozwiązuje problem wymazywania typów generycznych w JVM, zachowując informację o typach potrzebną w kolejnych etapach kompilacji.

2.2. Mechanizmy metaprogramowania w Scali 3

2.2.1. Definicje inline

Najprostszym narzędziem metaprogramowania jest modyfikator `inline`. Gwarantuje on, że wywołanie oznaczonej nim metody lub wartości zostanie w całości **wstawione w miejscu wywołania** (ang. *inlining*) podczas kompilacji. Jest to polecenie dla kompilatora, a nie tylko sugestia, jak w niektórych innych językach.

2.2.2. Makra oparte na wyrażeniach

Makra w Scali 3 są zdefiniowane jako metody `inline` zawierające *splice* najwyższego poziomu (ang. *top-level splice*)[25, 26], czyli taki, który nie jest zagnieżdżony w żadnym *Quotes* i jest wykonywany w czasie kompilacji[19, 25].

Typ `Expr[T]` reprezentuje wyrażenie Scali o typie `T` jako typowane drzewo składowe[22, 26]. Makra manipulują wartościami typu `Expr[T]`, transformując je lub generując nowe wyrażenia[26]. Ta reprezentacja gwarantuje bezpieczeństwo typów na poziomie języka metaprogramowania[22].

2.2.3. Dopasowanie wzorców kodu

Scala 3 wspiera analizę kodu poprzez dopasowanie wzorców w *quotes* (ang. *quote pattern matching*)[18, 21]. Mechanizm ten pozwala na dekonstrukcję kawałków kodu i ekstrakcję podwyrażeń[21].

Stucki, Brachthäuser i Odersky[21] wprowadzają wzorce wiążące (ang. *bind patterns*) postaci `$x` oraz wzorce HOAS (ang. *Higher-Order Abstract Syntax*) postaci `$f(y)`, które pozwalają na ekstrakcję podwyrażeń potencjalnie zawierających zmienne z zewnętrznego kontekstu[21]. System gwarantuje, że ekstrahowane wyrażenia są zamknięte względem definicji wewnątrz wzorca, zapobiegając wyciekom zakresu[21].

2.2.4. Refleksja TASTy

Dla przypadków wymagających głębszej analizy kodu, Scala 3 oferuje API refleksji TASTy[22, 23, 27]. TASTy jest binarnym formatem serializacji typowanych drzew składowych używanym przez kompilator Scali 3[18].

API refleksji dostarcza szczegółowy widok na strukturę kodu, włączając typy, symbole oraz pozycje w kodzie źródłowym[22, 27]. Jest dostępne poprzez obiekt `reflect` zdefiniowany w typie `Quotes`, który jest przekazywany kontekstualnie do makr[22, 27].

Rozdział 3

Implementacja

3.1. Praktyczna implementacja analizatora leksykalnego z wykorzystaniem makr w Scali 3

3.1.1. Wprowadzenie do studium przypadku

Niniejszy rozdział prezentuje praktyczną implementację systemu analizy leksykalnej (leksera) wykorzystującego zaawansowane mechanizmy metaprogramowania Scali 3. Przedstawiony kod stanowi przykład zastosowania technik opisanych w poprzednich rozdziałach do rozwiązania rzeczywistego problemu inżynierskiego: automatycznej generacji wydajnego analizatora leksykalnego z definicji wysokopoziomowej w formie języka dziedzinowego (DSL).

System `alpaca.lexer` implementuje transformację deklaracyjnych reguł tokenizacji zapisanych jako funkcja częściowa (ang. *partial function*) w kod proceduralny wykonywany w czasie kompilacji. Wykorzystuje przy tym pełne spektrum możliwości refleksji TASTy, włączając generację klas w czasie kompilacji, transformację drzew AST oraz wyspecjalizowane typy refinement.

3.1.2. Architektura systemu leksera

Interfejs użytkownika

System oferuje użytkownikowi przejrzysty interfejs DSL oparty na dopasowaniu wzorców:

```
1 type LexerDefinition[Ctx <: AnyGlobalCtx] = PartialFunction[String,  
    Token[?, Ctx, ?]]
```

Listing 3.1: Definicja typu `LexerDefinition`

Definicja `LexerDefinition` reprezentuje reguły leksera jako funkcję częściową mapującą wzorce wyrażeń regularnych (jako ciągi znaków) na definicje tokenów. Wykorzystanie funkcji częściowej pozwala na naturalne wyrażenie reguł leksykalnych w idiomatycznej składni Scali.

Główny punkt wejścia systemu stanowi metoda `lexer`:

```
1 transparent inline def lexer[Ctx <: AnyGlobalCtx & Product](  
2   using Ctx WithDefault DefaultGlobalCtx,
```

```

3 )(
4   inline rules: Ctx => LexerDefinition[Ctx],
5 )(using
6   copy: Copyable[Ctx],
7   betweenStages: BetweenStages[Ctx],
8 )(using inline
9   debugSettings: DebugSettings[?, ?],

```

Listing 3.2: Punkt wejścia: transparent inline def lexer

Modyfikator **transparent inline** zapewnia, że zwracany typ będzie dokładnie odpowiadał wygenerowanej strukturze, włączając typy refinement dla poszczególnych tokenów. Użycie parametrów kontekstowych (**using**) realizuje wzorzec dependency injection na poziomie systemu typów.

Implementacja makra

Makro przyjmuje wyrażenie reprezentujące reguły leksera jako **Expr[Ctx => LexerDefinition[Ctx]]** oraz instancje kontekstualnych klas pomocniczych. Parametr **using Quotes** dostarcza dostępu do API refleksji TASTy.

3.1.3. Analiza drzewa składni abstrakcyjnej

Dekonstrukcja funkcji częściowej

Kluczowym krokiem implementacji jest ekstrakcja reguł z definicji funkcji częściowej:

```

1 val createLambda = new CreateLambda[quotes.type]

```

Listing 3.3: Dekonstrukcja funkcji częściowej (dopasowanie AST do CaseDef)

Ten fragment kodu wykorzystuje dopasowanie wzorców w *quotes* do dekonstrukcji typowanego AST funkcji częściowej. Struktura **Lambda(_, Match(_, cases))** odpowiada wewnętrznej reprezentacji funkcji częściowej, gdzie **Match** zawiera listę przypadków **CaseDef**.

3.1.4. Transformacja i adaptacja referencji

Klasa replacerefs

Kluczową techniką jest zastąpienie referencji do starego kontekstu nowymi referencjami:

```

1 val (tokens, infos) = cases.foldLeft((List.empty[Expr[ThisToken]],
2   List.empty[TokenInfo[?]])):
3   case ((accTokens, accInfos), CaseDef(tree, None, body)) =>
4     def replaceWithNewCtx(newCtx: Term) = new
      ReplaceRefs[quotes.type].apply(
        (find = oldCtx.symbol, replace = newCtx),

```

Listing 3.4: Zastąpienie referencji starego kontekstu nowymi (ReplaceRefs)

Transformacja ta realizuje proces znany jako "re-owning" w terminologii kompilatorów — zmianę właściciela (owner) symboli w AST. Jest to konieczne, ponieważ kod oryginalnie

odnoszący się do parametru makra musi zostać przepisany, aby odnosił się do parametru metody w wygenerowanej klasie.

Klasa **ReplaceRefs** udostępnia **TreeMap**, który podczas przejścia po AST podmienia referencje do wskazanych symboli na podane termy. Umożliwia to tzw. re-owning — przeniesienie fragmentów kodu między różnymi właścicielami symboli bez ręcznego przepisywania drzew (por. ??).

3.1.5. Ekstrakcja i kompilacja wzorców

Funkcja `extractSimple`

Funkcja `extractSimple` implementuje logikę dopasowania różnych typów definicji tokenów:

```

1      )
2
3      def extractSimple(
4        ctxManipulation: Expr[CtxManipulation[Ctx]],
5      ): PartialFunction[Expr[ThisToken], List[Expr[ThisToken]]] =
6        case '{ Token.Ignored(using $ctx) } =>
7
8        case '{ type t <: ValidName; Token.apply[t]($value: v)(using $ctx)
9      } =>
10         compileNameAndPattern[t](tree).map:
11           case '{ $tokenInfo: TokenInfo[name] } =>
12             // we need to widen here to avoid weird types
13             TypeRepr.of[v].widen.asType match
14             case '[result] =>
15               val remapping = createLambda[Ctx => result]:
16                 case (methSym, (newCtx: Term) :: Nil) =>
17
18         replaceWithNewCtx(newCtx).transformTerm(value.asTerm)(methSym)

```

Listing 3.5: Funkcja `extractSimple`: dopasowywanie definicji tokenów

Wykorzystuje ona dopasowanie wzorców w *quotes* z ekstraktorem typów, umożliwiając rozróżnienie różnych wariantów definicji tokenów na poziomie typów. Konstrukcja `type t <: ValidName` w wzorcu wiąże parametr typu do zmiennej wzorca `t`, umożliwiając jego późniejsze wykorzystanie.

3.1.6. Analiza wzorców: klasa **CompileNameAndPattern**

Klasa **CompileNameAndPattern** stanowi kluczowy komponent systemu analizy leksykalnej, odpowiedzialny za ekstrakcję i walidację wzorców tokenów podczas ekspansji makra. Jej głównym zadaniem jest transformacja różnorodnych form wzorców występujących w definicjach DSL na ujednolicone struktury **TokenInfo**, które następnie są wykorzystywane do generacji finalnego kodu leksera.

Implementacja wykorzystuje rekurencyjne przetwarzanie drzewa AST z zastosowaniem optymalizacji rekurencji ogonowej (**@tailrec**), co zapewnia efektywność działania nawet dla złożonych wzorców z wieloma alternatywami.

3.1.7. Generacja klasy anonimowej

Anonimowa klasa implementująca `Tokenization[Ctx]` jest konstruowana programatycznie: (1) tworzymy symbol klasy przez `Symbol.newClass` wraz z listą deklaracji pól i typów; (2) budujemy ciało klasy (`ClassDef`) zawierające `ValDef` dla każdego zdefiniowanego tokena oraz pola `tokens` i `byName`; (3) określamy rodzica przez wywołanie konstruktora `Tokenization[Ctx]` z wymaganymi zależnościami; (4) instancjonujemy klasę i nadajemy jej typ zrefinowany przez kolejne `Refinement` odpowiadające polom-tokenom.

```

1      name = "byName",
2      tpe = TypeRepr.of[Map[String, DefinedToken[?, Ctx, ?]]],
3      flags = Flags.Synthetic | Flags.Lazy, // todo: reconsider lazy
4      privateWithin = Symbol.noSymbol,
5    )
6
7    tokenDecls ++ List(fieldsDecls, compiled, allTokens, byName)
8  }
9
10  val cls = Symbol.newClass(
11    Symbol.spliceOwner,
12    Symbol.freshName("$anon"),
13    List(TypeRepr.of[Tokenization[Ctx]]),
14    decls,
15    None,
16  )
17
18  val body = {
19    val tokenVals = definedTokens.collect:
20      case '{ $token: DefinedToken[name, Ctx, value] } =>
21        ValDef(
22          cls.fieldMember(ValidName.typeToString[name]),
23
24          Some(token.asTerm.changeOwner(cls.fieldMember(ValidName.typeToString[name]))),
25        )
26
27    tokenVals ++ Vector(
28      TypeDef(cls.typeMember("Fields")),
29      ValDef(
30        cls.fieldMember("compiled"),
31        Some {
32          val regex = Expr(
33            infos
34              .map:
35                case TokenInfo(_, regexGroupName, pattern) =>
36                  s"(?<$regexGroupName>$pattern)"
37              .mkString("|")
38              .r
39              .regex, // we'd like to compile it here to fail in compile
40              time if regex is invalid
41            )
42          '{ Regex($regex)
43        }.asTerm.changeOwner(cls.fieldMember("compiled"))
44      },
45    ),
46    ValDef(

```

```

44     cls.fieldMember("tokens"),
45     Some {
46         val declaredTokens = definedTokens.map:
47             case '{ $token: DefinedToken[name, Ctx, ?] } =>
48
49     This(cls).select(cls.fieldMember(ValidName.typeToString[name])).asExprOf[ThisToken
50
51         Expr.ofList(ignoredTokens ++
52         declaredTokens).asTerm.changeOwner(cls.fieldMember("tokens"))
53     },
54     ValDef(
55         cls.fieldMember("byName"),
56         Some {
57             val all = Expr.ofSeq {
58                 tokenVals.map(valDef => Expr.ofTuple((Expr(valDef.name),
59                 Ref(valDef.symbol).asExprOf[DefinedToken[?, Ctx, ?]])))
60             }
61             '{ Map($all*) }.asTerm
62         },
63     ),
64 }
65
66 val tokenizationConstructor =
67     TypeRepr.of[Tokenization[Ctx]].typeSymbol.primaryConstructor
68
69 val parents =
70     New(TypeTree.of[Tokenization[Ctx]])
71     .select(tokenizationConstructor)
72     .appliedToType(TypeRepr.of[Ctx])
73     .appliedToArgs(List(copy.asTerm, betweenStages.asTerm)) :: Nil

```

Listing 3.6: Generacja i instancjowanie anonimowej klasy `Tokenization[Ctx]` z typem rafinowanym

Typy refinement

Zwracany typ jest stopniowo rafinowany dla każdego tokena:

```

1     ),
2   ),
3 }
4
5 val tokenizationConstructor =
6     TypeRepr.of[Tokenization[Ctx]].typeSymbol.primaryConstructor

```

Listing 3.7: Rafinowanie typu wynikowego o pola tokenów

`Refinement(tpe, name, memberType)` tworzy typ refinement dodający członka o podanej nazwie i typie do bazowego typu. Pozwala to kompilatorowi śledzić, że zwrócony obiekt ma pola odpowiadające poszczególnym tokenom, umożliwiając dostęp do nich z pełnym wsparciem systemu typów.

3.1.8. Walidacja i obsługa błędów

Walidacja wzorców regularnych

System wykorzystuje pomocniczą klasę **RegexChecker** do walidacji wzorców:

Poniższy mechanizm sprawdza poprawność składni wyrażeń regularnych już w czasie kompilacji i raportuje błędy z dokładną lokalizacją wzorca. Metoda **report.errorAndAbort** jest częścią API kompilatora do raportowania błędów w czasie kompilacji. Przerwanie kompilacji w przypadku niepoprawnych wzorców zapewnia, że błędy konfiguracji są wykrywane możliwie wcześnie.

Obsługa nieobsługiwanych konstrukcji

Kod jawnie sygnalizuje nieobsługiwane przypadki: Obsługiwane są wyłącznie jasno zdefiniowane formy wzorców; w przypadku napotkania innej konstrukcji kompilacja jest przerywana z komunikatem zawierającym szczegóły AST, co upraszcza diagnostykę i utrzymuje zasadę fail-fast. Ta strategia jest zgodna z zasadą fail-fast - lepiej jest wyraźnie odrzucić nieobsługiwane konstrukcje niż milcząco generować niepoprawny kod.

3.2. Praktyczna implementacja generatora parserów z wykorzystaniem makr w Scali 3

3.2.1. Wprowadzenie do generatora parserów

System **alpaca.parser** stanowi zaawansowaną implementację generatora parserów LR(1), wykorzystującego metaprogramowanie Scali 3 do automatycznej konstrukcji tabel parsowania w czasie kompilacji. W przeciwieństwie do tradycyjnych generatorów parserów takich jak Yacc[2], które generują kod w osobnym kroku kompilacji, system ALPACA integruje generację parsera bezpośrednio w procesie kompilacji Scali, oferując pełne wsparcie systemu typów oraz natychmiastową walidację gramatyk.

Implementacja parsera reprezentuje znacznie bardziej złożone wyzwanie inżynierskie niż lekser, ze względu na konieczność: (1) konstrukcji automatów LR(1) i tabel parsowania, (2) obsługi konfliktów shift-reduce i reduce-reduce, (3) generacji akcji semantycznych zachowujących bezpieczeństwo typów, (4) oraz radzenia sobie z ograniczeniami platformy JVM dotyczącymi rozmiaru metod.

3.2.2. Interfejs API parsera

Definicja parsera

Użytkownik definiuje parser poprzez dziedziczenie po klasie bazowej **Parser[Ctx]**:

```

1 abstract class Parser[Ctx <: AnyGlobalCtx](
2   using Ctx WithDefault EmptyGlobalCtx,
3 )(using
4   empty: Empty[Ctx],
5   tables: Tables[Ctx],
6 ) {

```

Listing 3.8: Klasa bazowa Parser

Typ parametryczny **Ctx** reprezentuje globalny kontekst parsera, umożliwiając przechowywanie stanu między akcjami semantycznymi (np. tablicę symboli). Parametr kontekstualny **tables: Tables[Ctx]** jest automatycznie generowany przez makro i zawiera tabele parsowania oraz akcji semantycznych.

Definicja reguł gramatycznych

Reguły gramatyczne definiowane są jako wartości typu **Rule[R]**, gdzie **R** określa typ wyniku redukcji:

```

1 object CalcParser extends Parser[EmptyGlobalCtx] {
2   val Expr: Rule[Int] = rule(
3     { case (Expr(a), Lexer.PLUS(_), Expr(b)) => a + b },
4     { case Lexer.NUMBER(n) => n.value }
5   )
6
7   val root = rule { case Expr(result) => result }
8 }

```

Listing 3.9: Przykład definicji reguł parsera

Składnia wykorzystuje dopasowanie wzorców Scali do wyrażenia produkcji gramatycznych. Każdy przypadek (**case**) reprezentuje pojedynczą produkcję, gdzie lewa strona wzorca odpowiada prawej stronie produkcji gramatycznej, a wyrażenie po strzałce (\Rightarrow) definiuje akcję semantyczną. Na przykład wzorec **{ case (Expr(a), Lexer.PLUS(_), Expr(b)) => a + b }** odpowiada produkcji **Expr \rightarrow Expr PLUS Expr** z akcją sumującą wartości podwyrażeń.

3.2.3. Generacja tabel parsowania w czasie kompilacji

Makro createTablesImpl

Centralnym elementem systemu jest makro **createTablesImpl**, które analizuje definicję parsera i generuje tabele w czasie kompilacji:

```

1 private def createTablesImpl[Ctx <: AnyGlobalCtx: Type](
2   using quotes: Quotes,
3 )(
4   debugSettings: Expr[DebugSettings[?, ?]],
5 ): Expr[(parseTable: ParseTable, actionTable: ActionTable[Ctx])] = {

```

Listing 3.10: Sygnatura makra createTablesImpl

Makro wykonuje następujące kroki:

1. Ekstrakcja wszystkich reguł gramatycznych z definicji parsera poprzez refleksję TASTy
2. Transformacja wzorców dopasowania na produkcje gramatyczne
3. Konstrukcja automatów LR(1) i tabel parsowania
4. Generacja tabel akcji semantycznych
5. Walidacja gramatyki i rozwiązywanie konfliktów

Ekstrakcja produkcji z wzorców

Funkcja `extractEBNF` dokonuje transformacji wzorców dopasowania na produkcje gramatyczne:

```

1  def extractEBNF(ruleName: String): Expr[Rule[?]] => Seq[(production:
    Production, action: Expr[Action[Ctx]])] = {
2      case '{ rule(${ Varargs(cases) }*) }' =>
3          def createAction(binds: List[Option[Bind]], rhs: Term) =
            createLambda[Action[Ctx]]:
4              case (methSym, (ctx: Term) :: (param: Term) :: Nil) =>
5                  val seqApplyMethod =
            param.select(TypeRepr.of[Seq[Any]].typeSymbol.methodMember("apply").head)
6                  val seq = param.asExprOf[Seq[Any]]
7
8                  val replacements = (find = ctxSymbol, replace = ctx) ::
            binds.zipWithIndex
9                      .collect:
10                          case (Some(bind), idx) => ((bind.symbol,
            bind.symbol.typeRef.asType), Expr(idx))
11                      .map:
12                          case ((bind, '[t]), idx) => (find = bind, replace = '{
            $seq($idx).asInstanceOf[t] }.asTerm)
13                          case x => raiseShouldNeverBeCalled(x.toString)
14
15                      replaceRefs(replacements*).transformTerm(rhs)(methSym)
16

```

Listing 3.11: Ekstrakcja produkcji gramatycznych z wzorców

Kluczowym wyzwaniem jest zachowanie poprawności referencji do symboli przy przenoszeniu kodu akcji semantycznej z kontekstu definicji reguły do wygenerowanej tabeli akcji. Wymaga to zastosowania techniki *re-owning* symboli, realizowanej przez klasę `ReplaceRefs`.

3.2.4. Trudne problemy rozwiązane w implementacji

Problem ograniczenia rozmiaru metod JVM

Jednym z najbardziej interesujących wyzwań technicznych napotkanych podczas implementacji było ograniczenie rozmiaru metod w maszynach wirtualnych JVM. Zgodnie ze specyfikacją JVM[28], rozmiar kodu bajtowego pojedynczej metody nie może przekroczyć 65536 bajtów (64 KB). Dla złożonych gramatyk z dużą liczbą stanów i produkcji, wygenerowane tabele parsowania mogą zawierać tysiące wpisów, co przy naiwnej implementacji prowadziło do przekroczenia tego limitu.

Problem manifestował się podczas próby wyrażenia tabeli parsowania jako literału mapowego w kodzie:

```

1  // Ta implementacja generuje jeden żduy literal mapy
2  '{ Map(
3      (0, Terminal("PLUS")) -> Shift(1),
4      (0, Terminal("NUMBER")) -> Shift(2),
5      // ... ątysice kolejnych ółpisw ...
6      (999, Terminal("EOF")) -> Reduction(prod)
7  )}'

```

Listing 3.12: Naiwna implementacja prowadząca do przekroczenia limitu

Takie podejście generuje pojedynczą, dużą metodę zawierającą wszystkie wpisy tabeli, co dla gramatyk o rozmiarze produkcyjnym skutkuje błędem kompilacji `java.lang.ClassFormatError: Code length too large`.

Rozwiązanie: Problem został rozwiązany poprzez zastosowanie techniki *fragmentacji metod*. Zamiast generować jeden duży literal mapy, każdy wpis tabeli jest dodawany w osobnej, małej metodzie pomocniczej:

```

1      val additions = entries
2      .map(entry =>
3          '{
4              def avoidTooLargerMethod(): Unit = $builder += ${ Expr(entry) }
5              avoidTooLargerMethod()
6          }.asTerm,
7      )
8      .toList

```

Listing 3.13: Rozwiązanie problemu rozmiaru metod przez fragmentację

W tym podejściu:

- Tworzymy builder mapy jako zmienną lokalną (`Map.newBuilder`)
- Każde dodanie wpisu do buildera jest opakowane w osobną metodę `avoidTooLargerMethod()`
- Metody te są wywoływane sekwencyjnie jako lista wyrażeń w bloku
- Końcowy wynik jest uzyskiwany przez wywołanie `builder.result()`

Ta technika skutecznie obchodzi limit rozmiaru metody, ponieważ każda pomocnicza metoda zawiera tylko kilka instrukcji bajtowych, niezależnie od rozmiaru całej tabeli. Dodatkowo, kompilator JIT może efektywnie zoptymalizować i zinlinować te małe metody w czasie wykonania, eliminując narzut wydajnościowy.

Rozwiązanie to ilustruje ważną lekcję w metaprogramowaniu: kod generowany przez makra musi respektować wszystkie ograniczenia platformy docelowej, które normalnie są niewidoczne dla programistów piszących kod ręcznie.

Zachowanie bezpieczeństwa typów w akcjach semantycznych

Kolejnym istotnym wyzwaniem jest zapewnienie bezpieczeństwa typów w akcjach semantycznych podczas transformacji kodu z kontekstu makra do wygenerowanych tabel. Akcje semantyczne definiowane przez użytkownika mogą odwoływać się do:

- Kontekstu parsera (`ctx`)
- Wartości z dopasowanych symboli gramatycznych
- Zewnętrznych funkcji i wartości

Problem polega na tym, że te referencje muszą zostać przepisane podczas przenoszenia kodu akcji z miejsca definicji do tabeli akcji. Funkcja `createAction` realizuje tę transformację:

```

1      def createAction(binds: List[Option[Bind]], rhs: Term) =
      createLambda[Action[Ctx]]:
2          case (methSym, (ctx: Term) :: (param: Term) :: Nil) =>
3              val seqApplyMethod =
      param.select(TypeRepr.of[Seq[Any]].typeSymbol.methodMember("apply").head)
4              val seq = param.asExprOf[Seq[Any]]
5
6              val replacements = (find = ctxSymbol, replace = ctx) ::
      binds.zipWithIndex
7                  .collect:
8                      case (Some(bind), idx) => ((bind.symbol,
      bind.symbol.typeRef.asType), Expr(idx))
9                  .map:
10                      case ((bind, '[t]), idx) => (find = bind, replace = '{
11                          $seq($idx).asInstanceOf[t] }.asTerm)
12                      case x => raiseShouldNeverBeCalled(x.toString)
13
14              replaceRefs(replacements*).transformTerm(rhs)(methSym)

```

Listing 3.14: Tworzenie akcji semantycznej z zachowaniem referencji

Kluczowe aspekty implementacji:

1. **Parametryzacja akcji:** Akcja jest transformowana w funkcję przyjmującą kontekst (**ctx**) oraz listę dzieci w drzewie parsowania (**param**)
2. **Re-owning symboli:** Referencje do kontekstu parsera są zastępowane parametrem funkcji
3. **Ekstrakcja wartości:** Wartości z dopasowanych symboli są ekstrahowane z listy dzieci poprzez indeksowanie
4. **Rzutowanie typów:** System typów zapewnia, że ekstrakcje są bezpieczne względem typów dzięki informacji z wzorca dopasowania

Rozwiązywanie konfliktów gramatycznych

Parser LR może napotkać konflikty typu shift-reduce lub reduce-reduce podczas konstrukcji tabel parsowania. System ALPACA oferuje deklaracyjny mechanizm rozwiązywania takich konfliktów poprzez relacje precedencji:

```

1  override val resolutions = Set(
2      P.ofName("times").before(Lexer.PLUS),
3      P.ofName("plus").after(Lexer.TIMES)
4  )

```

Listing 3.15: Deklaracja rozwiązań konfliktów

Implementacja wykorzystuje klasę **ConflictResolutionTable**, która podczas konstrukcji tabeli parsowania:

1. Wykrywa konflikty między akcjami dla danego stanu i symbolu
2. Konsultuje zdefiniowane przez użytkownika relacje precedencji
3. Wybiera odpowiednią akcję zgodnie z deklaracją

4. Zgłasza błąd kompilacji dla nierozwiązanych konfliktów

To podejście umożliwia wyrażenie precedencji i łączności operatorów w sposób bardziej naturalny niż tradycyjne deklaracje `%left`, `%right` i `%nonassoc` w Yacc.

3.2.5. Generacja kodu tabel

Implementacja ToExpr dla złożonych struktur

System wymaga konwersji struktur danych w czasie kompilacji (wartości) na kod (wyrażenia `Expr[T]`). Realizowane jest to poprzez implementację instancji `ToExpr` dla typów `ParseTable` i `ActionTable`.

Implementacja `ToExpr[ParseTable]` jest szczególnie interesująca, gdyż musi radzić sobie z potencjalnie dużymi tabelami (patrz 3.2.4):

```

1  given ToExpr[ParseTable] with
2    def apply(entries: ParseTable)(using quotes: Quotes): Expr[ParseTable]
3    = {
4      import quotes.reflect.*
5
6      type BuilderTpe = mutable.Builder[
7        ((state: Int, stepSymbol: alpaca.parser.Symbol), Shift |
8        Reduction),
9        Map[(state: Int, stepSymbol: alpaca.parser.Symbol), Shift |
10        Reduction],
11        ]
12
13      val symbol = Symbol.newVal(
14        Symbol.spliceOwner,
15        Symbol.freshName("builder"),
16        TypeRepr.of[BuilderTpe],
17        Flags.Mutable,
18        Symbol.noSymbol,
19      )
20
21      val valDef = ValDef(symbol, Some('{ Map.newBuilder: BuilderTpe
22      }.asTerm))
23
24      val builder = Ref(symbol).asExprOf[BuilderTpe]
25
26      val additions = entries
27        .map(entry =>
28          '{
29            def avoidTooLargerMethod(): Unit = $builder += ${ Expr(entry) }
30            avoidTooLargerMethod()
31          }.asTerm,
32        )
33        .toList
34
35      val result = '{ $builder.result() }.asTerm
36
37      Block(valDef :: additions, result).asExprOf[ParseTable]
38    }

```

Listing 3.16: Implementacja ToExpr dla ParseTable

Ta implementacja demonstruje zaawansowane techniki metaprogramowania:

- Tworzenie nowych symboli (**Symbol.newVal**) reprezentujących zmienne w generowanym kodzie
- Konstrukcja definicji wartości (**ValDef**) z przypisaniem początkowym
- Generacja listy wyrażeń manipulujących builderem
- Składanie wszystkiego w blok kodu (**Block**) z finalnym wynikiem

3.2.6. Podsumowanie implementacji parsera

Implementacja generatora parserów w systemie ALPACA demonstruje zaawansowane zastosowanie metaprogramowania Scali 3 do rozwiązywania rzeczywistych problemów inżynierskich. Kluczowe osiągnięcia obejmują:

- **Automatyczna konstrukcja tabel LR(1)** w czasie kompilacji eliminująca potrzebę osobnego kroku generacji kodu
- **Pełna integracja z systemem typów Scali**, zapewniająca bezpieczeństwo typów w akcjach semantycznych
- **Eleganckie obejście ograniczeń platformy JVM** poprzez inteligentną fragmentację generowanego kodu
- **Deklaratywny mechanizm rozwiązywania konfliktów** oferujący większą elastyczność niż tradycyjne narzędzia
- **Natychmiastowa walidacja gramatyk** podczas kompilacji, z czytelnymi komunikatami o błędach

Problemy napotkane i rozwiązane podczas implementacji, szczególnie ograniczenie rozmiaru metod JVM, ilustrują istotne aspekty praktycznego metaprogramowania: generowany kod musi nie tylko być poprawny funkcjonalnie, ale również respektować wszystkie techniczne ograniczenia platformy docelowej.

Bibliografia

- [1] M. E. Lesk i E. Schmidt. *Lex: A lexical analyzer generator*. T. 39. Bell Laboratories Murray Hill, NJ, 1975.
- [2] S. C. Johnson i in. *Yacc: Yet another compiler-compiler*. T. 32. Bell Laboratories Murray Hill, NJ, 1975.
- [3] D. Beazley. *PLY (Python Lex-Yacc)*. 2005. URL: <https://www.dabeaz.com/ply/ply.html> (term. wiz. 19.03.2025).
- [4] D. Beazley. *SLY (Sly Lex-Yacc)*. 2016. URL: <https://sly.readthedocs.io/en/latest/sly.html> (term. wiz. 19.03.2025).
- [5] D. Beazley. *SLY Github*. URL: <https://github.com/dabeaz/sly> (term. wiz. 19.03.2025).
- [6] T. Parr, P. Wells, R. Klaren, L. Craymer, J. Coker, S. Stanchfield, J. Mitchell i C. Flack. *What's ANTLR*. 2004.
- [7] A. Moors, F. Piessens i M. Odersky. „Parser combinators in Scala”. W: *CW Reports* (2008).
- [8] *scala-parser-combinators Getting Started*. URL: https://github.com/scala/scala-parser-combinators/blob/main/docs/Getting_Started.md (term. wiz. 04.04.2025).
- [9] J. Boyland i D. Spiewak. „Tool paper: ScalaBison recursive ascent-descent parser generator”. W: *Electronic Notes in Theoretical Computer Science* 253.7 (2010).
- [10] A. A. Myltsev. „Parboiled2: A macro-based approach for effective generators of parsing expressions grammars in Scala”. W: *arXiv preprint arXiv:1907.03436* (2019).
- [11] L. Haoyi. *sfscala.org: Li Haoyi, FastParse: Fast, Programmable, Modern Parser-Combinators in Scala*. 2015.
- [12] *FastParse Getting Started*. URL: <https://com-lihaoyi.github.io/fastparse/#GettingStarted> (term. wiz. 04.04.2025).
- [13] L. Haoyi. *FastParse. Fast, Modern Parser Combinators*. URL: <https://www.lihaoyi.com/post/slides/FastParse.pdf> (term. wiz. 18.04.2025).
- [14] *Dropped: Scala 2 Macros. Scala 3 Reference*. URL: <https://docs.scala-lang.org/scala3/reference/metaprogramming/migrating/macro-compatibility.html> (term. wiz. 25.10.2025).
- [15] *Metaprogramming. Scala 3 Reference*. URL: <https://docs.scala-lang.org/scala3/reference/metaprogramming.html> (term. wiz. 25.10.2025).
- [16] N. Stucki. *Scalable Metaprogramming in Scala 3. EPFL Infoscience page*. 2024. URL: <https://infoscience.epfl.ch/entities/publication/6dd02f9b-1f9b-4c9c-9748-ddf1634c1630> (term. wiz. 25.10.2025).

-
- [17] N. Stucki, A. Biboudis, S. Doeraene i M. Odersky. „Semantics-preserving inlining for metaprogramming”. W: *Proceedings of the 11th ACM SIGPLAN International Symposium on Scala*. 2020. DOI: [10.1145/3426426.3428486](https://doi.org/10.1145/3426426.3428486). URL: <https://dl.acm.org/doi/10.1145/3426426.3428486>.
 - [18] N. Stucki. „Scalable Metaprogramming in Scala 3”. Prac. dokt. Lausanne: EPFL, 2020.
 - [19] *Runtime Multi-Stage Programming. Scala 3 Reference*. URL: <https://docs.scala-lang.org/scala3/reference/metaprogramming/staging.html> (term. wiz. 25.10.2025).
 - [20] N. Stucki, J. Brachthäuser i M. Odersky. „A practical unification of multi-stage programming and macros”. W: *Proceedings of the 9th ACM SIGPLAN International Symposium on Scala*. 2018. DOI: [10.1145/3278122.3278139](https://doi.org/10.1145/3278122.3278139). URL: <https://dl.acm.org/doi/10.1145/3278122.3278139>.
 - [21] N. Stucki, A. Biboudis i M. Odersky. „Multi-stage programming with generative and analytical macros”. W: *Proceedings of the 12th ACM SIGPLAN International Symposium on Scala*. 2021. DOI: [10.1145/3486609.3487203](https://doi.org/10.1145/3486609.3487203). URL: <https://dl.acm.org/doi/10.1145/3486609.3487203>.
 - [22] *Reflection. Scala 3 Reference*. URL: <https://docs.scala-lang.org/scala3/reference/metaprogramming/reflection.html> (term. wiz. 25.10.2025).
 - [23] *Reflection - Scala 3 - EPFL (Dotty docs)*. URL: <https://dotty.epfl.ch/docs/reference/metaprogramming/reflection.html> (term. wiz. 25.10.2025).
 - [24] *Quoted Code / Macros in Scala 3*. URL: <https://docs.scala-lang.org/scala3/guides/macros/quotes.html> (term. wiz. 25.10.2025).
 - [25] *Macros. Scala 3 Reference*. URL: <https://docs.scala-lang.org/scala3/reference/metaprogramming/macros.html> (term. wiz. 25.10.2025).
 - [26] *Scala 3 Macros*. URL: <https://docs.scala-lang.org/scala3/guides/macros/macros.html> (term. wiz. 25.10.2025).
 - [27] *Reflection / Macros in Scala 3*. URL: <https://docs.scala-lang.org/scala3/guides/macros/reflection.html> (term. wiz. 25.10.2025).
 - [28] T. Lindholm, F. Yellin, G. Bracha i A. Buckley. *The Java Virtual Machine Specification, Java SE 8 Edition*. Java SE 8. Specyfikacja JVM definiuje limit rozmiaru kodu bajtowego metody na 65536 bajtów. Addison-Wesley Professional, 2014.

Spis rysunków

Spis tabel

1.1	Porównanie wybranych narzędzi do generowania lekserów i parserów	11
-----	--	----

Spis algorytmów

Spis listingów

1.1	Fragment definicji parsera Ruby w technologii Yacc	6
1.2	Fragment definicji parsera w Pythonie, wykorzystujący bibliotekę <i>SLY</i> . . .	7
1.3	Fragment nie działającego kodu w Pythonie, wykorzystujący bibliotekę <i>SLY</i>	8
1.4	Przykładowy komunikat błędu w bibliotece <i>SLY</i>	8
1.5	Fragment błędu wygenerowanego przez bibliotekę <i>parboiled2</i>	9
3.1	Definicja typu <i>LexerDefinition</i>	14
3.2	Punkt wejścia: <code>transparent inline def lexer</code>	14
3.3	Dekonstrukcja funkcji częściowej (dopasowanie AST do <i>CaseDef</i>)	15
3.4	Zastąpienie referencji starego kontekstu nowymi (<i>ReplaceRefs</i>)	15
3.5	Funkcja <i>extractSimple</i> : dopasowywanie definicji tokenów	16
3.6	Generacja i instancjowanie anonimowej klasy <i>Tokenization[Ctx]</i> z typem rafinowanym	17
3.7	Rafinowanie typu wynikowego o pola tokenów	18
3.8	Klasa bazowa <i>Parser</i>	19
3.9	Przykład definicji reguł parsera	20
3.10	Sygnatura makra <i>createTablesImpl</i>	20
3.11	Ekstrakcja produkcji gramatycznych z wzorców	21
3.12	Naiwna implementacja prowadząca do przekroczenia limitu	21
3.13	Rozwiązanie problemu rozmiaru metod przez fragmentację	22
3.14	Tworzenie akcji semantycznej z zachowaniem referencji	23
3.15	Deklaracja rozwiązań konfliktów	23
3.16	Implementacja <i>ToExpr</i> dla <i>ParseTable</i>	24